



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学校

上海理工大学

参赛队号 23102520378

1.张红柳

队员姓名 2.杜沅昊

3.邹冰音

中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

题 目

强对流降水临近预报

摘要：

强对流降水是一种最常见的灾害性天气，其突发性和局地性强、生命史短、灾害重等特点极易给人民生产和生活带来巨大的破坏和伤害。如果可以提前预知此类天气状态，则可以挽回巨大的生命财产损失，尤其是短时（0~12 小时）和临近（0~2 小时）阶段是转移和应对灾害天气的黄金时期。对强对流降水的临近预报和准确评估成为一项极具挑战性的重要课题。本文从机理分析和数学模型的角度，借助传统物理方法和深度学习模型两种方式建立强对流降水临近预报模型，研究双偏振雷达观测数据和降水微物理结构之间的关系，预测临近雷达数据和定量降水估测，最后建立降水综合贡献度指标体系，并优化数据融合策略，不断提高预测精度，以便更好地为应对突发灾害性天气提供理论指南。

问题 1：将问题 1 拆分为问题 1-1 和问题 1-2。

问题 1-1：根据双偏振雷达变量 (Z_H , Z_{DR} , K_{DP}) 求解降水微物理结构信息。根据问题描述将双偏振雷达数据提取为 Z_H , Z_{DR} , K_{DP} 三个变量，将降水微物理结构提取为降水粒子大小、相态、含水量三个变量，问题转化为以双偏振雷达变量 (Z_H , Z_{DR} , K_{DP}) 作为输入，用雨滴谱反推技术求解降水粒子大小、用模糊逻辑法求解相态、用线性回归方法含水量。

问题 1-2：建立深度学习强对流临近预报模型并预测未来 1 小时的雷达观测量 Z_H 。以 U-Net 和 ConvLSTM 为基础，分别训练 1km、3km、7km 三个等高面的预报模型，输入前面一小时（10 帧）的雷达观测量 (Z_H , Z_{DR} , K_{DP})，输出后续一小时（10 帧）的 Z_H 预报，最后进行模型评估和对比分析。

问题 2：优化问题 1 中的临近预报模型，缓解模糊效应。从数据增强和模型优化两方面解决问题。首先借助生成对抗网络 (GAN) 生成额外的训练数据，帮助深度学习模型获取更多的数据特征信息。然后引入注意力机制和残差结构进行模型优化，解决模型的输入序列缺乏区分度问题和深层神经网络中的梯度消失或梯度爆炸的问题，构建基于传统 U-Net 的改进模型 GAN-AR-U-Net。后面与问题 1 中相同，分别训练 1km、3km、7km 三个等高面的预报模型，输入前面一小时（10 帧）的雷达观测量 (Z_H , Z_{DR} , K_{DP})，输出后续一小时（10 帧）的 Z_H 预报，最后进行模型评估和对比分析。

问题 3：借助雨滴谱拟合方法和深度学习模型完成定量降水估测并求解 $Z-R$ 关系。雨滴谱拟合降水量估测方法中，根据双偏振雷达降水估测公式，借助整体数据与分段雨强拟合方法完成 $Z-R$ 关系的拟合，随后进行两种拟合方法估测结果的分析和评估。基于深度学习的降水估测方法中，以问题 1、问题 2 为基础，构建基于 GAN-AR-U-Net 的定量降水估测网络模型，并将传统方法与深度学习方法输出结果做比较分析。模型输入为两个雷达变量 Z_H 和 Z_{DR} ，不考虑 K_{DP} ，输出降水量预测值。

问题 4: 构建降水综合贡献度指标体系和评估方法，优化数据融合策略以提高临近预报准确率。在本题中充分考虑双偏振雷达资料在降水量预报和降水微物理结构等方面的贡献，建立双偏振雷达资料“降水粒子半径-相态-含水量”的综合贡献度指标评估体系；构建基于模糊层次分析法 - 熵权法 - 逼近理想解排序法的双偏振雷达资料贡献度评估方法，分析降水的微物理结构贡献度最优选择策略，并将方案进行灵敏度检验；最后，通过算例，分析双偏振雷达资料中的三个变量对降水微物理结构三个指标的综合贡献度，及其灵敏度，优化双偏振雷达变量数据融合策略，为降水微物理结构和预报提出参考性建议。

关键词：强对流降水；双偏振雷达；微物理结构；雨滴谱；临近预报；深度学习模型；**U-Net**；**ConvLSTM**；生成对抗网络；注意力机制；残差结构；定量降水估测；贡献度评估；数据融合策略

目录

一、问题背景与问题重述	5
1.1 问题背景	5
1.2 问题重述	6
二、模型假设与符号说明	7
2.1 模型假设	7
2.2 符号说明	7
三、理论基础与技术准备	9
3.1 强对流降水短临预报	9
3.2 双偏振雷达观测	9
3.3 雨滴谱 DSD	9
3.4 卷积神经网络	10
3.5 循环神经网络	12
3.3 模型评价方法	13
四、问题 1 的模型建立与求解	15
4.1 问题分析	15
4.2 数据预处理（数据质量管理）	16
4.2.1 数据归一化	16
4.2.2 衰减修正	16
4.2.3 样本过滤	17
4.3 问题 1-1 求解：提取双偏振雷达数据中的微物理特征信息	18
4.3.1 根据双偏振雷达变量 (Z_H , Z_{DR} , K_{DP}) 求解降水粒子的大小	18
4.3.2 根据双偏振雷达变量 (Z_H , Z_{DR} , K_{DP}) 求解相态	19
4.3.3 根据双偏振雷达变量 (Z_H , Z_{DR} , K_{DP}) 求解含水量	19
4.4 问题 1-2 求解：建立深度学习短临预报模型预测雷达观测量	20
4.4.1 短临预报模型—U-Net	20
4.4.2 短临预报模型—ConvLSTM	20
4.4.3 短临预报模型—DGMR	21
4.4.4 基于短临预报模型预测雷达观测量 Z_H	22
4.4.5 模型评估和对比分析	28
5.1 问题分析	30
5.2 回归到平均（Regression to the mean）	30
5.3 短临预报方法改进及优化	30
5.3.1 生成对抗网络	30
5.3.2 注意力机制	31
5.3.3 残差结构	32
5.4 基于改进短临预报方法预测雷达观测量 Z_H	34
5.5 模型评估和对比分析	39
六、问题 3 的模型与求解	41
6.1 问题分析	41
6.2 定量降水估计 QPE	41
6.3 雨滴谱拟合降水估测方法的建立与评估	42
6.3.1 双偏振雷达降水估测公式	42

6.3.2 整体数据与分段雨强拟合方法	42
6.3.3 降水估测结果评估方法	42
6.3.4 两种拟合方法估测结果分析	43
6.4 基于深度学习的降水估测方法建立与分析	44
6.4.1 构建定量降水估测网络模型	44
6.4.2 传统方法与深度学习法估测性能对比	45
七、问题4的模型建立与求解	47
7.1 问题分析	47
7.2 基于模糊层次分析法-熵权法-逼近理想解排序法的双偏振雷达数据在强对流降水临近预报中的贡献度评估方法	47
7.2.1 方法介绍	47
7.2.2 降水指标综合贡献度指标选取及计算方法	48
7.3 基于其他方法的贡献评估	50
7.4 数据融合策略优化研究	50
八、模型评价与推广	51
8.1 模型的优点	51
8.2 模型的缺点	51
8.3 模型的改进与推广	51
参考文献	52
附录	54

一、问题背景与问题重述

1.1 问题背景

强对流天气对人们的生活和工作具有很大影响。由于我国辽阔的地域以及自然条件的复杂性，短时强降水、龙卷风等极端性灾害性天气呈多发频发态势。这种天气的出现不仅会对国家经济造成损失，同时也会对人们的生命安全造成威胁。如图 1-1 所示，为 2022 年 6 月 16-21 日暴雨灾害影响评估。部分地区由于暴雨遭受暴雨影响等级很高，城市、农田长时间积滞，地表生态环境和农作物受损严重。

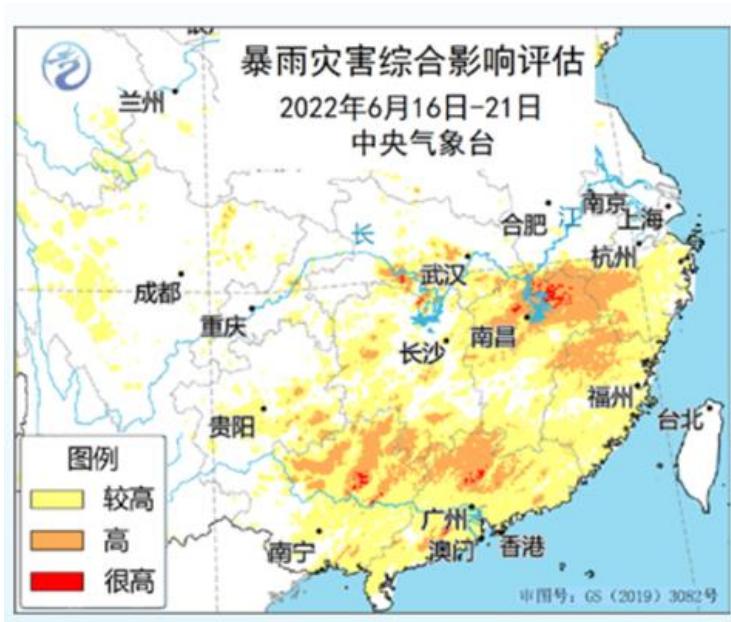


图 1-1 2022 年 6 月 16-21 日暴雨灾害影响评估

我国政府极为重视强对流天气带来的突发性问题。2021 年，国务院发布了《气象高质量发展纲要（2022-2035 年）》和《短时临近预报预警服务业务能力提升工作方案》部署要求。纲要指出，加强天气机理、气象灾害发生机理和地球系统多圈层相互作用等基础研究，强化地球系统数值预报模式、灾害性天气预报、气候变化等领域的科学和技术攻关^[1]。之后，气象局印发了《进一步提升国家级短时临近预报预警服务业务能力工作方案（2022-2035）》，进一步提升国家级应对强对流天气的短临预报预警服务能力。

强对流降水作为灾害性天气中最常见的一种，较其他极端性天气出现的更为频繁。它最显著的特点就是生命周期短、突发性强。在国家举办重大活动时，气象保障服务尤为重要，这就需要短临预报的协助。与短期预报相比，提前 1-2 小时的短临预报可以清楚的捕捉到系统所在的位置，从而能够预报出降雨的落区。这有利于活动方提前采取措施应对，以保障活动的顺利举行。此外，强对流降水还会影响到人们的出行和安全。最常见的就是航班延误和飞行安全。2021 年 7 月 20 日，郑州多地爆发强降雨，这导致郑州新郑机场多架航班被迫延误或取消，给旅客的出行造成了很大的影响^[2]。2020 年 8 月 7 日，印度航空公司一架波音 737-800 客机在尼加拉国际机场降落时遭遇暴雨，冒险着陆导致坠毁，且伤亡人数较多。因此，深入研究强对流天气系统的物理机理，提升灾害性天气精密监测和灾害性天气短时临近精准预报能力具有重要意义。

强对流天气临近预报使用的传统方法是依靠雷达等观测资料，并结合风暴识别、追踪技术进行雷达外推预报。该方法的目的是为得到未来时刻的雷达反射率因子，然后通过雷达反射率因子和降水之间的经验性关系（即 Z-R 关系）来估计未来某个时刻的降水量。近年来，随着物联网行业的发展，人类产生和储存的数据越来越多。与此同时，人工智能和深度学习技术成为各行各业研究的热点。深度学习方法作为一类数据驱动的方法，因大数据的积累而被广泛的使用。理论上，其性能随着训练数据量增大而提升的优点，使得该方法适用于有大量雷达观测数据支撑的短临预报领域。目前国际上的短临预报模型主要是以深度学习为基础，包括基于卷积神经网络（Convolutional Neural Networks, CNNs）和基于循环神经网络（Recurrent Neural Networks, RNNs）两类。其中，CNNs 中的 U-Net 模型^[3]和 RNNs 中的 ConvLSTM、DGMR 等模型^[4,5]已被用于强对流天气的短临预报。

本题针对双偏振雷达数据和降水格点数据展开研究，借助 U-Net、ConvLSTM、DGMR、QPE 等人工智能技术实现对突发性和局地性强的强对流降水短期临近精确预报。此外，还设计了数学模型以展示双偏振雷达数据中的微物理特征和降水量之间的关系及预报中的模糊效应。最后，根据对双偏振雷达资料在强对流降水临近预报中的贡献，设计数据融合策略，优化强对流降水的预报结果。在强对流降水临近预报问题中，双偏振雷达数据和降水格点数据作为重要因素，对两者的关系和贡献建模并分析具有重要的实际意义。因此，本问题的分析和求解具有较好的研究价值。

1.2 问题重述

基于前述研究背景，该题目提供两组数据，基于数据和问题的描述，拟要解决的研究问题如下：

- (1) 根据附件数据，建立可提取用于强对流临近预报双偏振雷达资料中微物理特征信息的数学模型，并以前面一小时的雷达观测量 (Z_H 、 Z_{DR} 、 K_{DP}) 为输入，输出后续一小时的 Z_H 预报；
- (2) 在问题 1 的基础上，设计数学模型解决预报中存在的模糊效应，尽可能消除和缓解“回归到平均”问题，使预报出的雷达回波细节更充分真实；
- (3) 根据附件数据中的 Z_H 、 Z_{DR} 和降水量，设计数学模型完成定量降水估计，使模型输入为 Z_H 、 Z_{DR} ，输出为降水量，并且本算法中不可使用 K_{DP} 变量；
- (4) 设计数学模型来评估双偏振雷达数据在强对流降水临近预报中的贡献，并优化数据融合策略，使其预报结果更加准确，从而更好地应对突发性局部地区的强对流天气。

二、模型假设与符号说明

2.1 模型假设

- (1) 雷达和降水样本数据属性完整、数据一致，无噪声数据问题；
- (2) 每个降水过程中的两帧之间的时间间隔均相同，不存在其他因素影响间隔差；
- (3) 降水数据为近似的地面降水，高度对降水结果无影响；
- (4) 在进行定量降水估计时，只考虑雷达观测量 Z_H 和 Z_{DR} ；
- (5) 近地面垂直气流很弱，可略去不计；
- (6) 所有雨滴的散射都满足瑞利散射条件。

2.2 符号说明

表 2-1 符号说明

符号	意义
Z_H	水平反射率因子
Z_{DR}	差分反射率
K_{DP}	比差分相移
D	粒径
N_o	截断参数
μ	形状因子
Λ	斜率参数
D_m	中值粒径
N_w	归一化的粒子数浓度
R	降水强度
M	液态含水量
POD	检测概率
FAR	虚警率
CSI	关键成功指标

符号	意义
$hits$	预报成功的个数
$misses$	漏报个数
$false_alarms$	错误识别个数
CC	相关系数
MSE	均方误差
$RMSE$	均方根误差
MAE	平均绝对误差
NE	归一化绝对误差
NB	归一化相对误差
a	经验性参数
b	经验性参数
R_i^{CAL}	估测公式计算的降水强度
R_i^{DSD}	雨滴谱观测数据计算的降水强度
n	数据样本对个数
ΔD_i	通道间距
α	权重系数
$R_{traditional}$	传统雷达的预报结果
$R_{dual-polarized}$	双偏振雷达的预报结果

三、理论基础与技术准备

3.1 强对流降水短临预报

短临预报（Nowcasting）指的是气象预报的时效范围，一般情况下主要集中在 0 小时到 12 小时之间。短期预报的时效范围在 1 到 3 天，相比较而言，短临预报的时效更短。短临预报主要应用于水平范围较小、生命期较短的天气系统，即中小尺度的天气系统，主要针对生消速度快，难以把握的强对流天气。这是因为强对流天气的生命周期往往很短，且多为突发性的情况，这刚好与短临预报的时效性契合。

短期预报一般只针对强对流天气出现的可能性进行预报，但却无法准确预报由强对流天气系统所产生的降雨区域范围以及降雨的猛烈程度。而短临预报却能解决这些问题。一般，提前 1 小时到 2 小时的短临预报能够捕捉到强对流系统所在的位置，从而预报出强对流天气所携带而来的降雨落区，以及衍生剧烈天气的影响范围。

3.2 双偏振雷达观测

对天气的观测，并且及时进行天气预报，尤其是对强对流天气的短临预报，可以及时的向公众发布灾害预警，具有重要的社会经济意义。随着现代科技发展和提供的观测天气和预警系统中，其中最重要、最关键的仪器之一就是气象雷达。雷达几乎是唯一的、必不可少的传感器，能够实时、准确地提供大面积的强风、强降水、冰雹等强对流天气现象的信息。最常用两种雷达是多普勒雷达和风廓线雷达。在实际应用中表明，这两种雷达在提供空间，特别是大气层低层的高分辨率数据方面具有极高的价值。多普勒雷达作为国家网络的一部分，并越来越多地在区域网络中广泛使用，主要用于恶劣天气现象的短程预报。其中特别有用的是多普勒雷达在进行风力测量和估计降雨量方面的能力。

偏振雷达（Polarimetric Radars）是在传统单偏振多普勒天气雷达的基础上添加额外的发射和处理功能，可以进一步计算出关于接收到的反射电磁能量方向性的额外信息。大多数气象雷达发射和接收的电波都是单一的、水平偏振的，电场波峰的方向沿水平轴对齐。偏振雷达则是同时发射和接收水平和垂直两极化的无线电波。尽管有许多不同的方法可以将水平和垂直脉冲混合到传输方案中，但最常用的方法是在水平和垂直极化之间交替使用每个连续脉冲。在每一个传输脉冲后都有一个短暂的监听期，在此期间，雷达会接收和解释来自云层的反射信号。偏振雷达发射和接收水平和垂直偏振的无线电波脉冲。因此，他们同时测量云和降水粒子的水平和垂直方向上的维度。这些附加信息改进了雷达对降水类型和速率的估计。

3.3 雨滴谱 DSD

雨滴谱资料研究对进一步了解对流云团内部的微物理结构特征、雷达定量估测降水和改进数值预报模式有重要意义。雨滴谱资料是由雨滴谱仪获得，我国最常用的是激光雨滴谱。如图 3-1 显示的是地面激光雨滴谱仪，它可以同时观测水凝物粒子的数量、尺度和下落速度。



图 3-1 地面激光雨滴谱仪

其原理是：激光发射装置发出一束水平激光，再由激光接收装置将接收到的水平光转换成电子信号；当降水粒子穿过水平光束时以其相应的直径遮挡部分光束，因而使接收装置输出的电压下降。通过电压的大小可以确定降水粒子的等效直径大小，实现降水粒子的粒径检测；降水粒子下落通过水平激光束需要一定的时间，通过检测电子信号的持续时间，即从降水粒子开始进入光束到完全离开光束所经历的时间，可以推导出降水粒子的下落速度。再根据降水类型特征，对降水粒子的大小和速度均采用不等间隔的分级方法，分级粒度由细到粗逐渐增大，不同种类降水粒子的数量分布构成了雨滴谱（raindrop size distribution, DSD）。

光学类雨滴仪的测量精度可能会受到强风和强降水的影响，导致观测到的直径和下落速度信息失真^[6]。此外，如果粒子不完全在光束内，它们可能被记录为小粒子，比在同一尺寸下观测到的其它粒子下落得更快^[7]。为确保数据质量，当总雨滴数目小于 10 或计算的雨强小于 0.1 mm h^{-1} 时，则该数据被视为噪声^[8]。

3.4 卷积神经网络

卷积神经网络（Convolutional neural network, CNN）是一类包含卷积计算且具有深度结构的前馈神经网络。主要用来处理具有类似网格结构的数据的神经网络。例如，时间序列数据（可以认为是在时间轴上有规律地采样形成的以为网格）和图像数据（可以看作是二维的像素网格）。CNN 的核心思想是通过卷积操作来提取时间按序列、图像等数据的特征，从而实现对数据的分类、识别等任务。卷积神经网络的结构如图 3-2 所示：

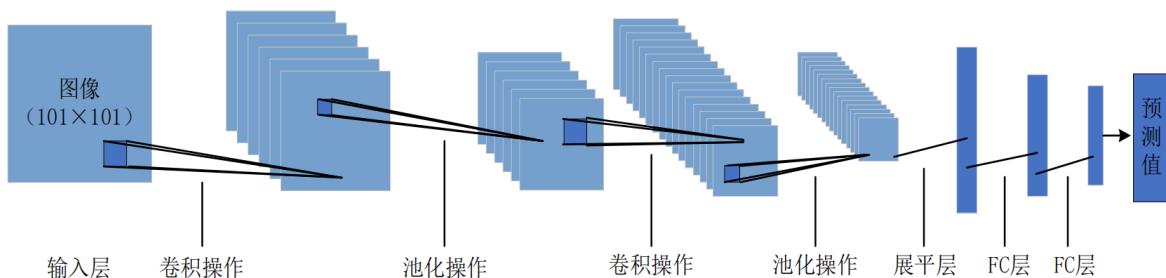


图 3-2 卷积神经网络的结构

CNN 的基本结构由卷积层、池化层和全连接层组成。

(1) 卷积层

卷积层是 CNN 的核心，其内部包含多个卷积核，组成卷积核的每个元素都对应一个权重系数和一个偏差量。卷积核的所覆盖的区域，被称为“感受野 (respective field)”。卷积层是通过滑动一个卷积核在输入数据上进行卷积操作，从而提取出数据的局部特征。

卷积是数学分析中的一种积分变换的方法，在图像处理中采用的是卷积的离散形式。这里需要说明的是，在 CNN 中，卷积层的实现方式实际上是数学中定义的互相关 (cross-correlation) 运算，与数学分析中的卷积定义有所不同，使用互相关运算作为卷积的定义。

互相关是衡量两个序列相关性的函数，通常是用滑动窗口的点积计算来实现。而卷积则需要将滤波器经过反转。一维卷积经常用在信号处理中，用于计算信号的延迟累积。假设一个信号发生器每个时刻 t 产生一个信号 x_t ，其信息的衰减率为 w_k ，即在 $k-1$ 个时间步长后，信息为原来的 w_k 倍。而在时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加，即：

$$y_t = w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} = \sum_{k=1}^3 w_k \cdot x_{t-k+1} \quad (3.1)$$

其中， w_k 被称为滤波器 (filter) 或卷积核 (convolution kernel)。

在实际应用中，卷积层通常包含多个卷积核，每个卷积核可以提取不同的特征，从而得到多个输出特征图。这些特征图可以输入到池化层或下一个卷积层中，进一步提取和组合特征，最终得到网络的输出结果。

(2) 池化层 (pooling layer)

池化层，也称汇聚层、子采样层，其主要作用是进行特征选择，降低特征数量，从而减少参数数量。池化相当于在空间范围内做了维度约减，分别作用于每个输入的特征并减小其大小。

池化层包含预设定的池化函数，其功能是将特征图中单个点的结果替换为其相邻区域的特征图统计量。使用某一位置的相邻输出的总体统计特征代替网络在该位置的输出，其好处是当输入数据做出少量平移时，经过池化函数后的大多数输出还能保持不变。

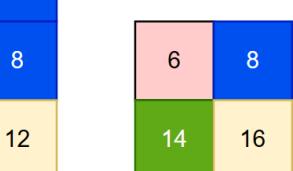
池化通常有两种：平均池化和最大池化，如图 3-3 所示。

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16



(a) Average pooling

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16



(a) Max pooling

图 3-3 平均池化和最大池化

(a) 平均池化 (Average Pooling)，计算区域内所有元素的平均值，其计算方式如式 (3.2) 所示。

$$Y_{m,n}^d = \frac{1}{|C_{m,n}^d|} \sum_{i \in C_{m,n}^d} x_i \quad (3.2)$$

(b) 最大池化 (Maximum Pooling), 即返回一个区域内所有元素的最大值, 其计算方式如式 (3.3) 所示。

$$Y_{m,n}^d = \max_{i \in C_{m,n}^d} x_i \quad (3.3)$$

式 (3.2) 和式 (3.3) 中, x_i 为子区域 C_i^d 内每个元素的数值, $Y^d = \{Y_{m,n}^d\}, 1 \leq m \leq M, 1 \leq n \leq N$

表示输出的池化特征。

(3) 全连接层 (fully-connected layer)

全连接层本身不具有特征提取能力, 而是使得目标特征图失去空间拓扑结构, 被展开为向量。它主要是对提取的特征进行非线性组合以得到输出。

CNN 的优点在于它能够自动学习和提取数据的特征, 无需手动进行特征工程。此外, CNN 还具有平移不变性、参数共享等特点, 使得模型具有较好的泛化能力和鲁棒性。需要注意的是, 建模过程中卷积神经网络的设计和调优非常重要。因此, 对于输入数据进行预处理, 如图像数据进行归一化、中心化等操作, 可以提高模型的训练效果和泛化能力。

3.5 循环神经网络

循环神经网络 (Recurrent Neural Network, RNN) 是一类用于处理序列数据的神经网络, 它是在全连接神经网络的基础上增加了前后时序上的关系。其核心思想是利用该网络内部很强的记忆性来处理任意时序的输入序列, 所以在处理具有时序性的问题时展现出很好的适用性, 被广泛的应用在语音识别、语言模型以及自然语言生成等任务上。这同样为气象领域带来了启发, 对于本文研究的降水预测问题, 降水数据之间有着时序上的联系, 利用 RNN 可以较好的抓取降水数据之间的时序信息, 这有助于提高降水预测的准确性。

RNN 的网络结构如图 3-4 所示:

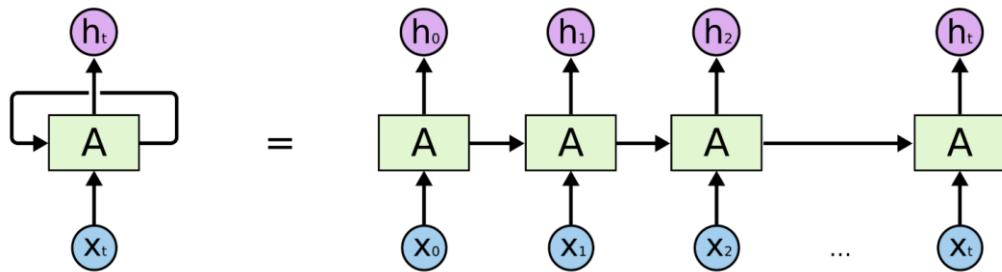


图 3-4 循环神经网络结构

RNN 会受到短时记忆的影响, 适用于处理的是长期依赖的问题, 可如果输入的关键信息间隔较大, RNN 会丧失学习远距离信息的能力, 导致遗漏重要信息, 并且在反向传播期间面临梯度消失或梯度爆炸的问题。长短期记忆网络 (Long Short-Term Memory, LSTM) 是一种改进之后的循环神经网络, 作为 RNN 的变体, 可以在一定程度上解决反向传播期间梯度消失以及梯度爆炸等问题。LSTM 网络结构如图 3-5 所示:

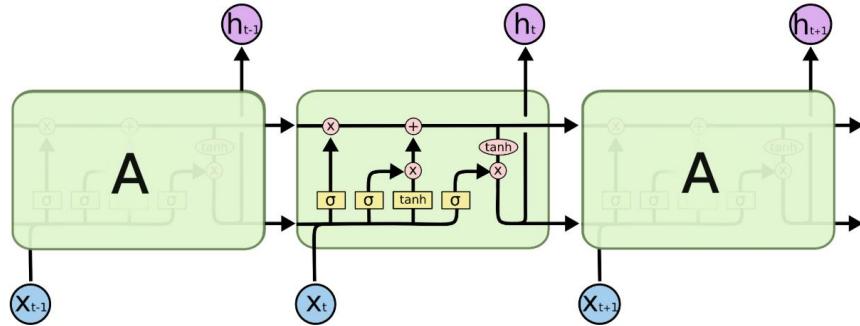


图 3-5 长短期记忆神经网络结构

LSTM 中的重复模块包含四个交互的层，三个 Sigmoid 和一个 tanh 层，并以一种非常特殊的方式进行交互。LSTM 利用三种类型的门结构：遗忘门、输入门和输出门，来保护和控制细胞状态。

表 3-1 LSTM 的三个门

中文名称	英文名称	作用
遗忘门	Forgetgate	它决定了上一时刻的记忆单元状态 c_{t-1} 有多少保留到当前时刻 c_t
输入门	Inputgate	它决定了当前时刻网络的输入 x_t 有多少保存到记忆单元 c_t
输出门	Outputgate	控制记忆单元状态 c_t 有多少输出到 LSTM 的当前输出值 h_t

LSTM 模型训练过程采用随时间反向传播算法 (BPTT)，将误差值逐层向上传递，当前时刻之前的几乎所有状态值及结果值都会对当前权重的更新产生影响，从而使模型具有长时间记忆的功能。

3.3 模型评价方法

为了评价模型临近预报的效果，本文采用降水事件探测指标，包括检测概率 (Probability Of Detection, POD)、虚警率(False Alarm Ration, FAR)，关键成功指标(Critical Success Index, CSI)，其计算公式如下：

$$POD = \frac{hits}{hits + misses} \quad (3.4)$$

$$FAR = \frac{false_alarms}{hits + false_alarms} \quad (3.5)$$

$$CSI = \frac{hits}{hits + misses + false_alarms} \quad (3.6)$$

上述公式中，hits 表示预报成功的个数，即模型预报图上有降水且在实际雷达回波

图中也有降水的个数；misses 表示漏报个数，即模型预报图上无降水但在实际雷达回波图中有降水的个数；false_alarms 表示错误识别个数，即模型预报图中有降水但在实际雷达回波图中无降水。POD 代表模型对降水正确预报的比率，FAR 是模型对降水事件的虚警率，CSI 给出了整体的正确判断率。理想情况下模型的各项指标应该是 $POD=1$, $FAR=0$, $CSI=1$ 。hits, misses, false_alarms 是通过对单幅模型预报图像和实际雷达回波图像的每个格点计算所得，根据所得结果求解出单幅图像的 POD, FAR, CSI。本文的模型，每次预报输出五张图像。在计算各项指标时，计算的是五张图像指标的平均值。如果是对指定时间点的预报准确性进行分析，则只需计算当前时刻对应图像的 POD, FAR, CSI。

对强对流天气短时临近预报进行检验，可以促进短临预报技术的发展。近年来，除了使用相关系数、探测概率(POD)和虚假警报比(FAR)和临界成功指数(CSI,即 TS 评分)、ETS(Gilbert SkillScore)评分等来衡量强对流天气短时临近预报的好坏，还发展了许多新的空间检验方法，主要有四类：第一类为邻域空间检验方法(Neighborhood methods)，也称为模糊检验；第二类为尺度分离检验方法；第三类为场变形(Field deformation)检验方法；第四类为基于对象或者特征（Object/Feature-based）的检验方法。

四、问题 1 的模型建立与求解

4.1 问题分析

首先分析题目中给出的数据，本题中给出的双偏振雷达数据包含三个变量：

(a) Z_H , 水平反射率因子, 即水平方向的回波强度, 单位通常为 dBZ, 主要反映降水的强弱;

(b) Z_{DR} , 差分反射率, 即水平和垂直方向回波强度的差异, 主要反映了观测区域的降水粒子大小;

(c) K_{DP} , 比差分相移, 即单位距离上降水粒子导致的水平和垂直方向回波的相位差, 主要反映了液态含水量。

双偏振雷达资料中的微物理特征信息包含：

(a) 降水粒子的大小;

(b) 相态;

(c) 含水量等。

双偏振雷达资料中包含数据：

(a) 三个双偏振雷达变量 (Z_H 、 Z_{DR} 、 K_{DP})；

(b) 三个等高面 (1km, 3km, 7km);

(c) 每个等高面都有对应的 258 次降水观测数据;

(d) 每次降水过程中, 每 6 分钟观测 1 次, 即每 6 分钟得到 1 帧数据;

(e) 观测范围为 256*256km。

因此, 对问题 1 进行分析, 可以将其划分为两个小问题进行求解:

问题 1-1: 利用题目提供的数据, 建立可提取用于强对流临近预报双偏振雷达资料中微物理特征信息的数学模型, 即从双偏振雷达数据 (Z_H 、 Z_{DR} 、 K_{DP}) 中提取微物理特征 (降水粒子大小、相态、含水量, 即雨滴谱信息 DSD)。

问题 1-2: 构建强对流短临预报深度学习模型, 输入前面一小时 (10 帧) 的雷达观测量 (Z_H 、 Z_{DR} 、 K_{DP}), 输出后续一小时 (10 帧) 的 Z_H 预报。

问题 1 的解题思路主要分为五个阶段：数据预处理→拆分问题→提取双偏振雷达数据中的微物理特征→建立深度学习短临预报模型预测雷达变量→得到结果。问题 1 的解题流程如图所示：

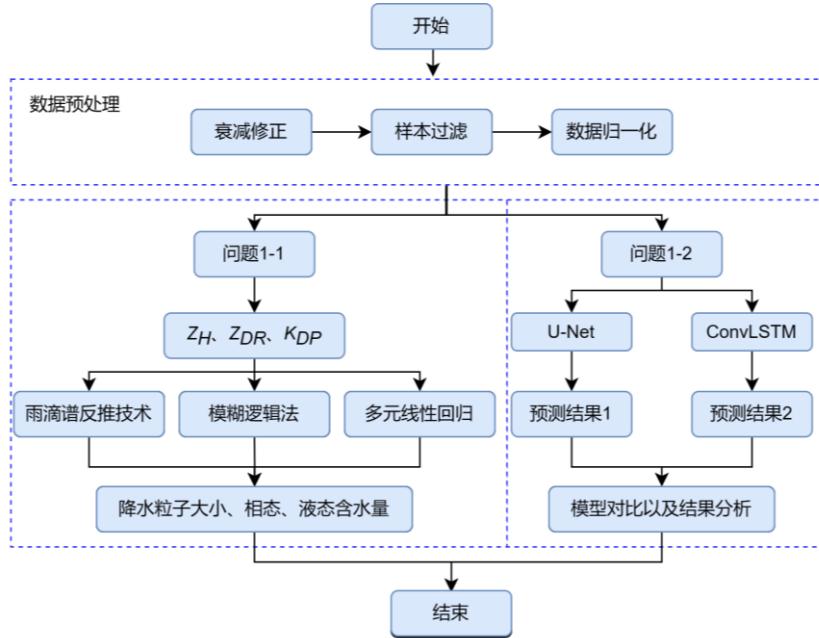


图 4-1 问题 1 的解题流程

4.2 数据预处理（数据质量管理）

4.2.1 数据归一化

数据首先需要采用 `mapminmax()` 函数进行归一化处理，目的在于消除因量纲不同对预测结果造成的影响：

$$x^* = \frac{(x - x_{\min})(y_{\max} - y_{\min})}{x_{\max} - x_{\min}} + y_{\min} \quad (4.1)$$

其中 y_{\max}, y_{\min} 为设定的上界与下界，分别为 1 和 0； x 为待归一化样本数据， x_{\max} 和 x_{\min} 分别为样本数据的最小值和最大值， x^* 为样本数据归一化处理后得到的结果。

4.2.2 衰减修正

衰减修正的方法有很多，比如径向剖面修正、差分反射率法、双偏振法、多普勒修正和地基校正等。本文根据雷达数据的特点，使用径向剖面修正法。

径向剖面修正（Radar Reflectivity Profiling）是一种基于雷达观测垂直剖面的方法。通过测量大气中不同高度层次的反射率，并根据大气衰减的模型进行修正，可以获得更准确的降水反射率因子。本文采用径向剖面修正中传统的距离修正方法。

距离修正方法通常涉及到将反射率数据插值或外推到所需的距离上。插值方法可以使用简单的线性插值或更复杂的插值算法，如双线性插值或径向插值。

线性插值模型如公式 (4.2)

$$Q(d) = a * Z_1 + (1 - a) * Z_2 \quad (4.2)$$

其中， $Q(d)$ 是距离为 d 的修正后的反射率， Z_1 和 Z_2 是距离为 d_1 和 d_2 的原始反射率，

a 是权重系数。

数学原理：假设有两个已知点 (x_1, y_1) 和 (x_2, y_2) ，其中 $x_1 < x_2$ ，要估计在这两个点之间某个位置 x 的值 y 。线性插值模型基于以下线性关系：

$$y = y_1 + \frac{(x - x_1)}{(x_2 - x_1)} \cdot (y_2 - y_1) \quad (4.3)$$

上述公式中， y 是未知点的估计值， x 是未知点的位置， x_1 和 x_2 是已知点的位置， y_1 、 y_2 是已知点的值。

4.2.3 样本过滤

卡尔曼滤波（Kalman Filter）是一种用于估计系统状态的递归滤波方法，通常应用于动态系统的状态估计和预测。它在估计中考虑了系统的动态模型和测量模型，以融合来自不同源头的信息，从而提供更准确的状态估计。卡尔曼滤波广泛用于许多领域，包括航空航天、导航、自动控制、金融等。

以下是卡尔曼滤波法的基本原理和数学模型：

基本原理：通过融合两种信息源来提高状态估计的准确性，这两种信息源是：

系统动态模型：描述了系统状态如何随时间演变的数学模型，通常表示为状态转移矩阵（A）和控制输入矩阵（B）。

传感器测量：由传感器获取的实际测量数据，通常包含噪声。

卡尔曼滤波通过不断更新状态估计值，以适应新的测量数据，并根据系统动态模型进行状态预测。这一过程分为两个主要步骤：

预测步骤（Prediction Step）：根据系统的动态模型，使用上一时刻的状态估计值来预测当前时刻的状态。这一步骤产生了预测状态估计值和预测误差协方差矩阵。

更新步骤（Update Step）：将传感器测量数据与预测状态进行比较，以纠正预测状态并提高估计的准确性。这一步骤产生了更新后的状态估计值和更新后的误差协方差矩阵。

卡尔曼滤波的主要目标是最小化估计误差的方差，以获得最优的状态估计。

(1) 状态预测方程

状态预测：

$$x_k = Ax_{k-1} + Bu_k \quad (4.4)$$

误差协方差预测：

$$P_k = AP_{k-1}A^T + Q \quad (4.5)$$

(2) 状态更新方程

卡尔曼增益计算：

$$K_k = P_k H^T \left(H P_k H^T + R \right)^{-1} \quad (4.6)$$

更新状态估计：

$$x_k = x_k + K_k (z_k - Hx_k) \quad (4.7)$$

更新误差协方差：

$$P_k = (I - K_k H) P_k \quad (4.8)$$

其中, x_k 是当前时刻的状态估计; u_k 是当前时刻的控制输入 (如果有); z_k 是当前时刻的传感器测量; A 是状态转移矩阵; B 是控制输入矩阵; H 是测量矩阵; P_k 是误差协方差矩阵, 表示状态估计的不确定性; Q 是过程噪声协方差矩阵, 表示系统动态模型中的噪声; R 是传感器测量噪声协方差矩阵, 表示测量数据的噪声; K_k 是卡尔曼增益, 用于融合预测和测量信息。

经以上三种方式的数据处理后, 得到降噪后的数据。由于篇幅限制, 这里只放一处数据修正和降噪后的可视化展示, 如下图 4-2 所示。

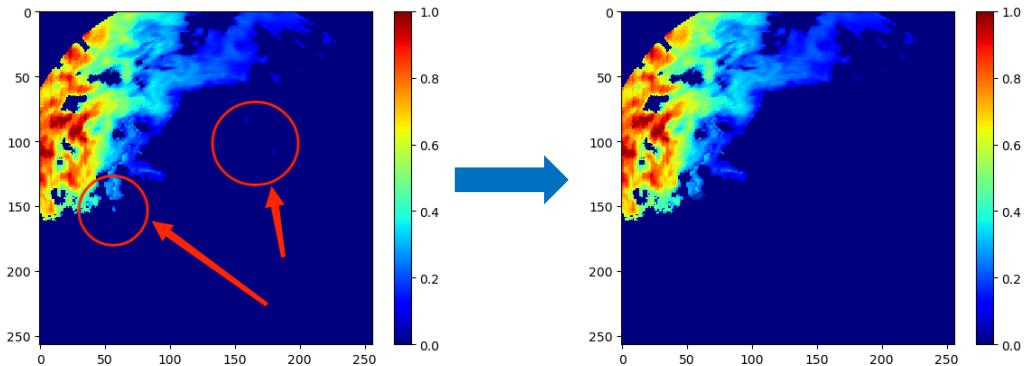


图 4-2 双偏振雷达水平反射率因子降噪前后对比图

由图中可以看出, 经过归一化、衰减修正、样本过滤后的数据图谱, 消除了异常值, 左侧图为未进行质控的 Z_H , 右侧图为质控后的 Z_H 。

4.3 问题 1-1 求解: 提取双偏振雷达数据中的微物理特征信息

通过查阅文献和阅读扩展内容, 我们提取出以下信息:

雨滴谱数据和双偏振雷达数据相关。雨滴谱是云降水物理的重要研究课题之一, 通过自动或者手动方式的雨滴谱观测可获取观测点上雨滴谱尺度分布、形状、以及降雨强度等参数, 而气象雷达的遥感探测能提供较大体积范围内的降雨分布结构等特征, 但在定量测量小降水方面却存在很大的不确定性。所以, 通常需要利用雨滴谱的直接测量结果对气象雷达观测的降雨量进行订正-进而分析区域降雨的微物理结构特征, 这对于提高雷达定量估计降水精度具有重要的意义。因此, 可以根据雨滴谱数据估计双偏振雷达数据, 也可以实现根据双偏振雷达数据反演得到雨滴谱数据。

综上, 将问题 1-1 分解为 3 个子问题, 即根据双偏振雷达变量 (Z_H 、 Z_{DR} 、 K_{DP}) 分别求解雨滴谱微物理信息 (降水粒子大小、相态、含水量)。

4.3.1 根据双偏振雷达变量 (Z_H 、 Z_{DR} 、 K_{DP}) 求解降水粒子的大小

采用的双偏振雷达雨滴谱反演技术基于约束 Γ 分布模型 (简称 C-G 模型)。该模型的原型雨滴谱为 Γ 分布, Γ 分布模型一般表示为

$$N(D) = N_0 D^\mu \exp(-\Lambda D) \quad (4.9)$$

式中, D 为粒径, N_0 是截断参数 ($m^{-3} mm^{-1-\mu}$), μ 是形状因子, Λ (mm^{-1}) 是斜率参数。已有研究表明^[9], Γ 模型的 3 个参数不是相互独立的, 其中和存在统计上的非线性关系, C-G 模型基于统计的 μ - Λ 关系式, 利用双偏振变量反射率因子 (Z_H) 和差分反射率因子 (Z_{DR}) 与降水粒子粒径 (D) 的对应关系, 反演得到雨滴谱参数及变量。其中,

μ - A 关系通过位于南京江宁（位于溧水雷达西北约 35km 处）的二维视频雨滴谱仪在 2014-2015 年夏季的观测数据拟合确定的^[10]，其关系式如下：

$$\mu = -0.0302A^2 + 1.0537A - 2.4526 \quad (4.10)$$

利用 μ - A 关系以及雷达观测到的 Z_H 和 Z_{DR} 即可计算得到 Γ 分布的 N_0 、 μ 、 A 三个控制参数；并通过反演的雨滴谱特征计算出降水微物理参数如质量权重中的中值粒径 (D_m)、归一化的粒子数浓度 (N_w) 等。

4.3.2 根据双偏振雷达变量 (Z_H 、 Z_{DR} 、 K_{DP}) 求解相态

所使用的双偏振雷达相态分类方法是一种模糊逻辑算法^[11]，利用 Z_H 、 Z_{DR} 、 K_{DP} 、 ρ_{hv} 、 Φ_{DP} 以及探空等资料作为输入变量，可将雷达回波分为雨和冰雹、大雨、雨、大雨滴、霰、冰晶、湿雪、干雪、生物回波、地物等 10 种不同类型。其具体步骤是：

(1) 采用梯形隶属函数对特定回波采样点上所有输入变量进行模糊化，得到各个输入变量对于不同类型回波的概率取值，某一回波类型的概率值越大则该类回波类型的可能性越高。

(2) 对该回波采样点上各类回波类型的所有输入变量概率值进行加权累加，获得各回波类型的最终得分值，最大得分数值对应的回波类型即为识别的相态种类。需要指出的是，基于该方法识别的某一回波采样点上的回波类型，只表明该类粒子在此采样体积内出现的概率最大，并不表明没有其他类型降水粒子存在。

4.3.3 根据双偏振雷达变量 (Z_H 、 Z_{DR} 、 K_{DP}) 求解含水量

利用散射的计算结果，不考虑降水强度 $R > 200 \text{ mm h}^{-1}$ 、 $M > 10 \text{ g m}^{-3}$ 和反射率因子 $Z_H > 60 \text{ dBZ}$ 的情况，我们给出了 15000 个不同滴谱分布所对应的降水强度 R (mm h^{-1})、液态含水量 M (单位： g m^{-3})、 Z_H (单位： $\text{mm}^6 \text{m}^{-3}$)、 Z_{DR} (单位： dBZ)、 K_{DP} [单位： $(\circ) \text{ km}^{-1}$]。利用一元线性回归和多元线性回归方法，经过对数转换就得到了几种双参数和单参数 C 波段双线偏振多普勒天气雷达测量降水强度和液态含水量的公式^[12]：

$$\begin{aligned} R(Z_{DR}, K_{DP}) &= 35.71 Z_{DR}^{-0.465} K_{DP}^{0.942}, \\ R(Z_H, Z_{DR}) &= 0.01013 Z_H^{0.885} Z_{DR}^{-1.485}, \\ M(Z_{DR}, K_{DP}) &= 2.04 Z_{DR}^{-0.640} K_{DP}^{0.889}, \\ R(Z_H, Z_{DR}) &= 0.0009267 Z_H^{0.833} K_{DP}^{-1.599}, \end{aligned} \quad (4.11)$$

$$\begin{aligned} R(K_{DP}) &= 28.76 K_{DP}^{0.779}, \\ M(K_{DP}) &= 1.514 K_{DP}^{0.673}, \end{aligned} \quad (4.12)$$

其中 (Z_{DR}, K_{DP}) 、 (Z_H, Z_{DR}) 和 (K_{DP}) 分别代表利用 Z_{DR} 、 K_{DP} 、 Z_H 和 K_{DP} 反演降水强度和液态含水量的方法。根据 (4.11)、(4.12) 式，我们就可以利用 C 波段双线偏振多普勒雷达来反演降水强度和液态含水量。雷达测量降水或业态含水量的误差除了雷达本身性能和雷达定标而引起的雷达探测量的误差外，雨滴谱的变化式雷达测量降水或液态含水量的主要因素。

4.4 问题 1-2 求解：建立深度学习短临预报模型预测雷达观测量

与 3.2 相同地，查阅文献和阅读扩展内容，提取出以下信息：

针对强对流降水短临预报问题，双偏振雷达探测数据有数据量巨大、观测值容易出现偏差和异常等特点，一般采用雷达标定、衰减订正、比差分传播相移的估计以及非气象回波的识别和剔除等方法进行数据预处理，短临预测模型最常用的是 U-Net 和 ConvLSTM。本题首先对数据进行归一化，然后使用衰减修正、样本过滤两种方法对数据做降噪处理后，分别采用 U-Net 和 ConvLSTM 两种深度学习训练模型，并输入前一个小时（10 帧）数据预测后一个小时（10 帧）数据，最后进行模型评估和对比分析。

4.4.1 短临预报模型—U-Net

U-Net 网络结构最早由 Ronneberger 等人于 2015 年提出。该图像的核心思想是引入了跳跃连接，使得图像分割的精度大大提升。

U-Net 属于编码-解码网络，由两部分组成。编码部分用于特征提取，经过 3×3 卷积和激活函数 ReLU 后，再通过一个最大池化层操作完成一次下采样；解码部分用于特征融合，经过拼接操作、 3×3 卷积核 ReLU 函数激活后，再通过一个反卷积操作完成一次上采样。四次上采样核四次下采样操作后，最终经过 1×1 卷积核激活函数 Sigmoid 输出。

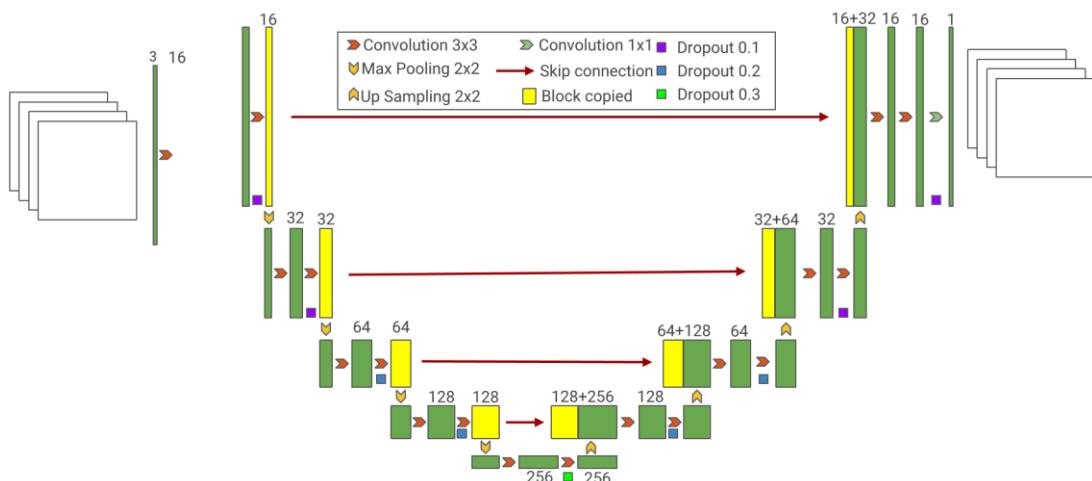


图 4-3 U-Net 结构图

4.4.2 短临预报模型——ConvLSTM

RNN 中长短期记忆网络（LSTM）在处理时间相关性问题上有着较好的学习能力，但是空间数据中的局部特征会造成空间冗余等问题。而深度学习中 CNN 对空间数据的局部特征学习能力极强，可以学习雷达数据空间上的局部特征信息。因此，结合两者的优势，本文采用 ConvLSTM，可以更好地学习雷达数据之间的空间特征信息和时序信息，从而有助于提高降水预测模型的准确性。

卷积长短期神经网络（Convolutional Long Short-Term Memory, ConvLSTM）是在模型的底层结合卷积神经网络和长短期记忆神经网络的模块。对于现在的降水预报，每个时间段的观测结果都是二维雷达回波图。如果将雷达回波图划分成不重叠的图块，并将回波图块内的像素点作为其测量值来看，短临预报问题就变成了对时空序列预测问题。

ConvLSTM 模型由一个编码器和一个解码器组成，其中编码器用于提取回波运动规律，解码器用于预测未来一段时间的回波序列，解码器的初始状态由编码器提供。ConvLSTM 的模型结构如图 4-4 所示。

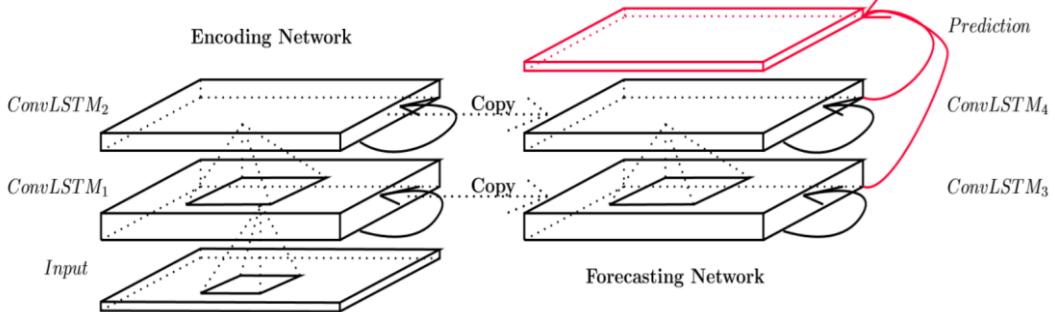


图 4-4 ConvLSTM 模型结构图

ConvLSTM 的本质还是和长短期记忆神经网络一样，将上一层的输出作为下一层的输入，但是通过加入卷积操作之后，不仅大大降低了参数的总数，还使得神经网络可以同时提取时间和空间特征。ConvLSTM 模型的计算流程如下：

$$\begin{aligned}
 i_t &= \sigma(W_{xi} * \chi_t + W_{hi} * H_{t-1} + W_{ci} \circ C_{t-1} + b_i), \\
 f_t &= \sigma(W_{xf} * \chi_t + W_{hf} * H_{t-1} + W_{cf} \circ C_{t-1} + b_f), \\
 C_t &= f_t \circ C_{t-1} + i_t \circ \tanh(W_{xc} * \chi_t + W_{hc} * H_{t-1} + b_c), \\
 o_t &= \sigma(W_{xo} * \chi_t + W_{ho} * H_{t-1} + W_{co} \circ C_t + b_o), \\
 h_t &= o_t \circ \tanh(C_t)
 \end{aligned} \tag{4.13}$$

其中， i 表示 LSTM 记忆块内的输入门。它可以去除一些不需要的信息，对隐藏层 Cell 的状态输入进行控制； f 表示 LSTM 记忆块内的遗忘门。它用于控制记忆块上一个时间点所存储的历史信息，经该门计算之后，选择性对隐藏层 Cell 的输出进行处理； o 表示 LSTM 记忆块内的输出门。它决定历史信息是否能输出给下一层，它用于对隐藏层 Cell 的状态输出进行控制。 σ 表示 sigmoid 激活函数，“ $*$ ” 表示卷积操作；“ \circ ” 表示 Hadamard 乘积，表示矩阵与对应元素相乘。

如果将 ConvLSTM 中的传递状态视为运动对象的隐藏表示，具有较大过渡核的 ConvLSTM 应该能够捕捉到较快的运动，而具有较小的过渡核的 ConvLSTM 则能够捕捉到较慢的运动，从而获得比 LSTM 更好的预测精度。由于卷积长短期记忆神经网络既拥有对时间序列相关性的处理能力，又能在历史观测资料上学习并捕捉到降水空间上的变化特征，而降水是一个一系列的具有时间序列特征的数据。因此，本文主要使用长短期卷积神经网络对降水进行预报的研究。

4.4.3 短临预报模型——DGMR

DGMR (Deep Generative models of radar) 称为深层降雨生成模型，它是将深度生成模型 (Deep Generative models, DGM) 应用在预测降雨量方面^[4]。DGM 是一种统计模型，其学习数据的概率分布并且允许从其学习的分布生成样本。由于这种基本上是概率性质的，它们能够模拟给定的历史雷达的条件分布的许多样本，生成预测集合。因此，根据 DGM 既能从观测数据中学习，又能在多个空间和时间尺度上表示不确定性的特点，使得称为新型实用的临近预报方法。它可以预测由于潜在的随机性而难以预测的较小尺度的天气现象，这是临近预报研究的关键问题。

雷达生成模型 (Generative models of radar), 临近预报算法是一个条件生成模型, 它使用在给定时间点 T 的基于雷达的地表降水 X_T 估计, 在给定 M 个过去或上下文雷达场的情况下预测 N 个未来雷达场。其模型包括潜在随机向量 Z 和参数 θ , 由下式描述:

$$P(X_{M+1:M+N} / X_{1:M}) = \int P(X_{M+1:M+N} / Z, X_{1:M}, \theta) P(Z / X_{1:M}) dZ \quad (4.14)$$

4.4.4 基于短临预报模型预测雷达观测量 Z_H

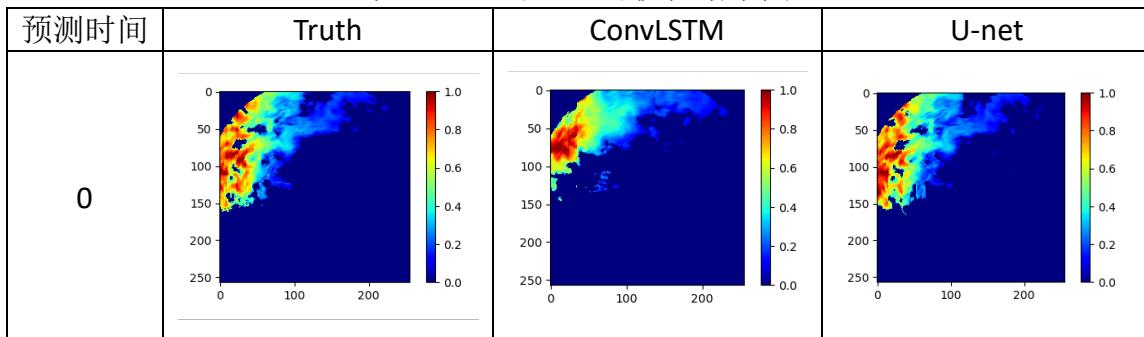
本题是一个经典的借助深度学习模型处理强对流降水临近预报问题, 选取 U-Net 和 ConvLSTM 两个模型分别做对比实验, 根据模型的选取不同划分为实验 1 和实验 2, 下面以实验 1 为例描述实验过程, 实验 2 除模型选取外, 均与实验 1 相同。

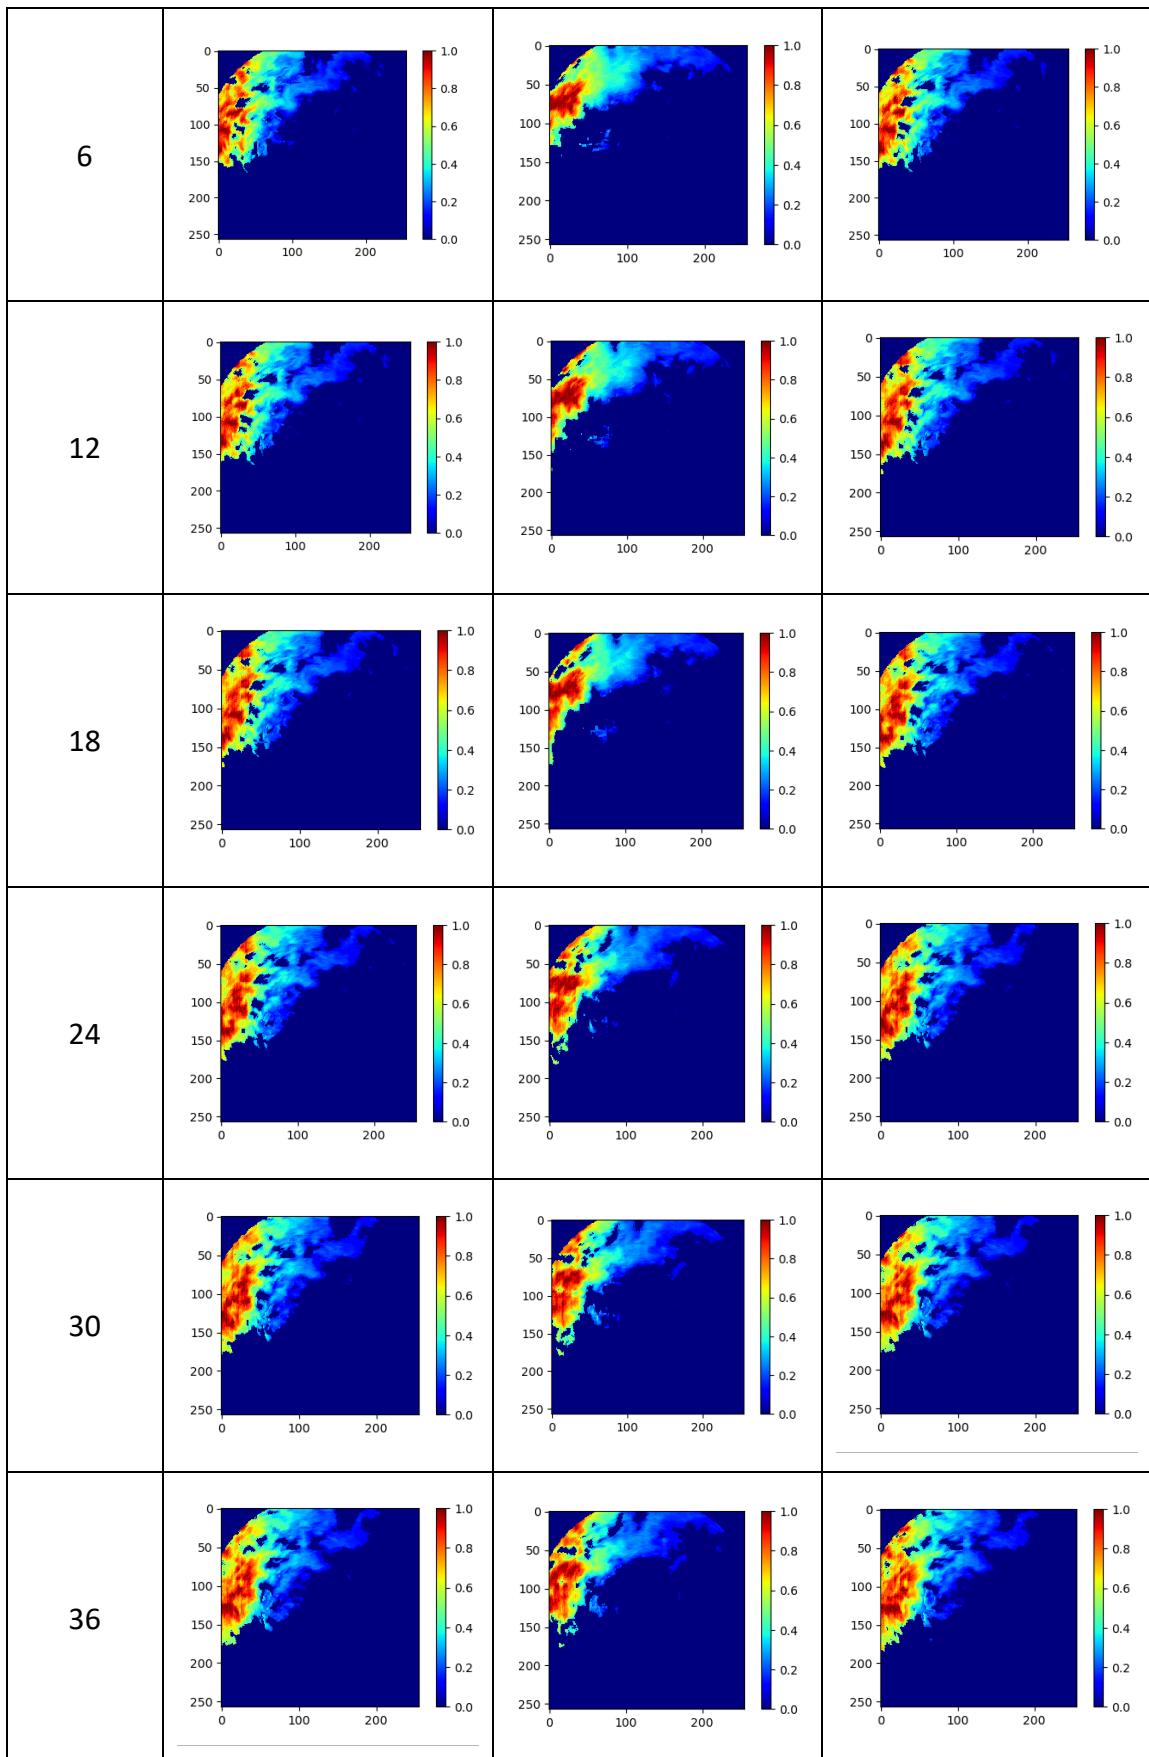
实验 1 包括基于 U-Net 的短临预报模型训练和测试过程, 其中实验数据来自题目给出的双偏振雷达探测数据 <https://box.nju.edu.cn/f/16bbb37458d3443dbf9f/?dl=1>, 此数据中包括 Z_H 、 Z_{DR} 、 K_{DP} 三个变量, 每个变量数据包括 1km、3km、7km 三个等高面观测的 258 次降水数据, 每次降水过程由于时长不同导致数据量也不同, 每 6 分钟记录 1 帧数据, 每帧数据范围是 256km×256km 的平面区域。将数据按照等高面分为三组, 根据数据的不同再次将实验 1 划分为 3 组子实验, 即实验 1-1 (1km 数据)、实验 1-2 (3km 数据)、实验 1-3 (7km 数据)。下面再以实验 1-1 为例, 详细展开实验过程, 实验 1-2、实验 1-3 除数据外, 均与实验 1-1 相同。

经过以上数据和子实验的划分后, 实验 1-1 数据包含双偏振雷达数据 Z_H 、 Z_{DR} 、 K_{DP} 三个变量, 每个变量数据包含 258 次降水观测数据, 其中三个变量的值在时刻上是相对应的。将三个变量数据按照时刻整理, 同一时刻的变量数据放到一起, 形成 258 组时间序列数据。接下来按照 7:3 的比例划分训练集和测试集, 前面 180 次降水数据作为训练集, 后面 78 次降水数据作为测试集。在实验 1-1 中, 训练 U-Net 模型学习训练集数据中 Z_H 、 Z_{DR} 、 K_{DP} 三个变量的特征及其关于时间的变化特征。模型训练中的具体设置为: pow 设为 0.4, batch size 设为 256, 使用 Adam 优化器, 学习率为 $1e-4$, 最大训练轮次为 120, 随机种子设置为 3407, 显卡使用 Nvidia Tesla V100, 每次训练取验证集上最佳的模型保存参数, 然后在测试集上进行测试。测试过程中的输入为前面一小时 (10 帧) 的雷达观测量 (Z_H 、 Z_{DR} 、 K_{DP}), 输出为后续一小时 (10 帧) 的 Z_H 预报。

经过实验得到训练好的 U-Net-1km、U-Net-3km、U-Net-7km 模型和 ConvLSTM-1km、ConvLSTM-3km、ConvLSTM-7km 模型并得到分别的 Z_H 输出结果, 由于篇幅限制, 此处只展示等高面为 1km、3km、7km, 第 1 次降水过程中以前面一小时 (frame000-frame009) 数据作为输入, 后面一小时 (frame010-frame019) Z_H 数据作为输出的分别的可视化结果。由于数据量较大, 其他结果可通过运行附件中代码获得。

表 4-1 1km 处 Z_H 可视化结果图





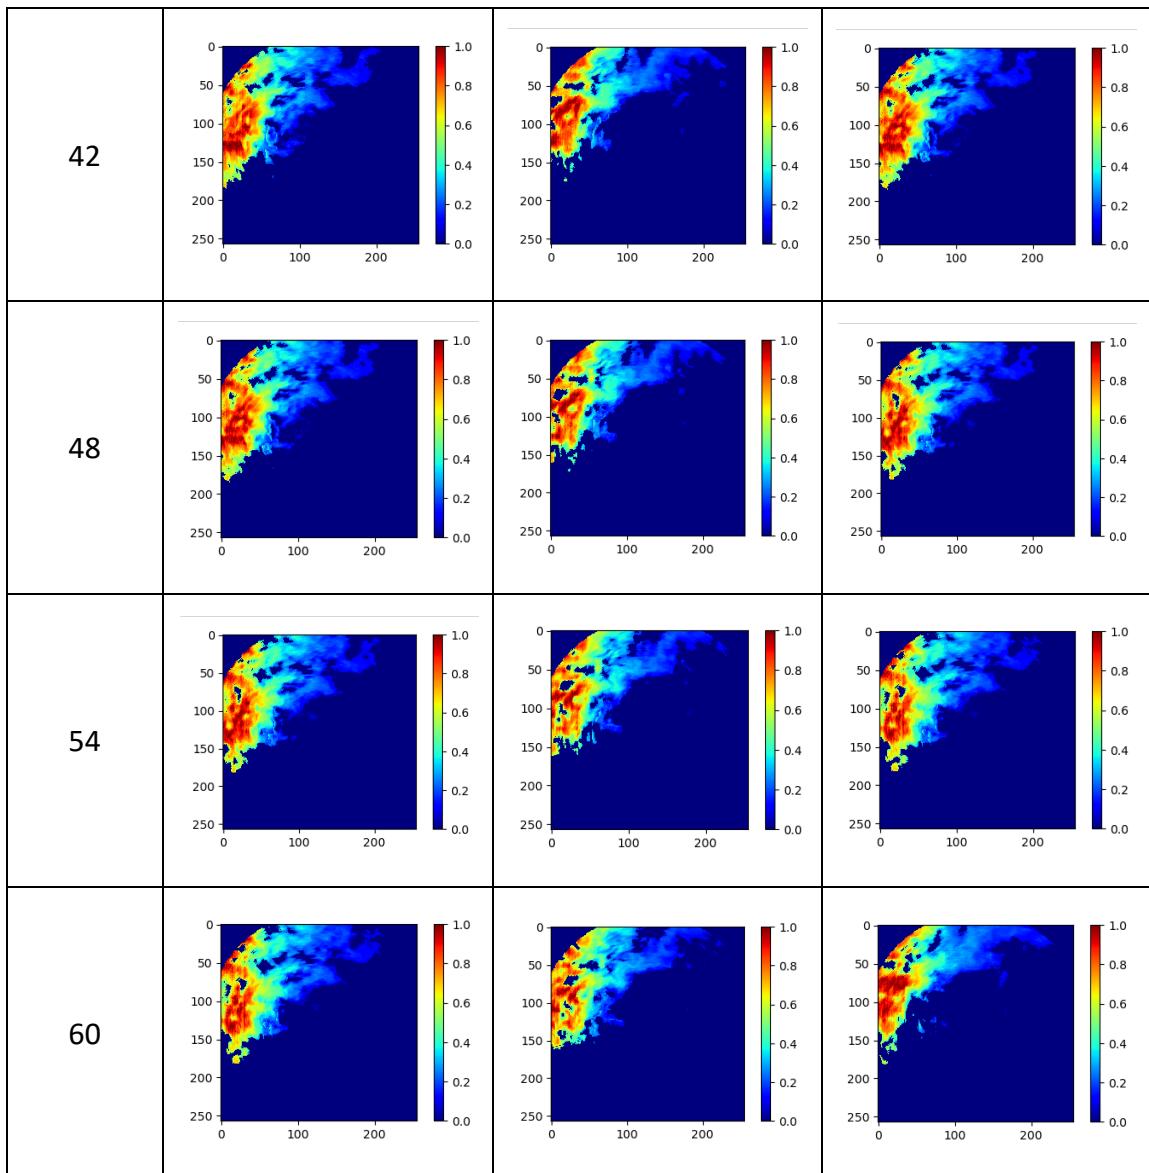
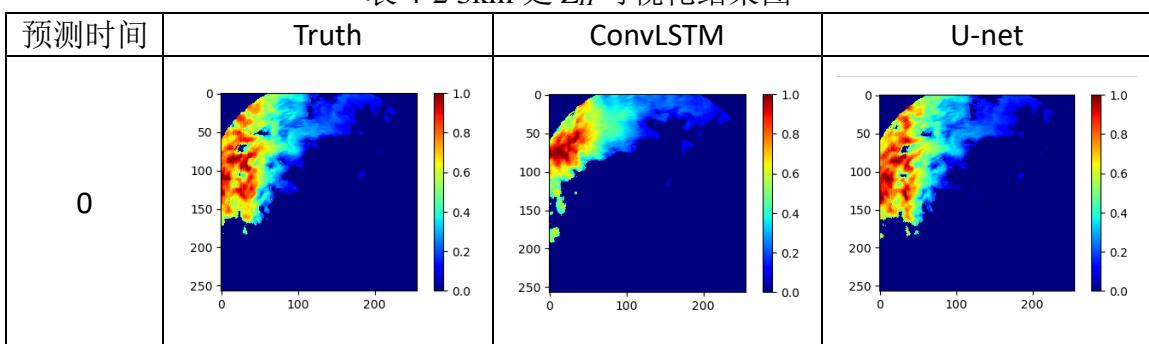
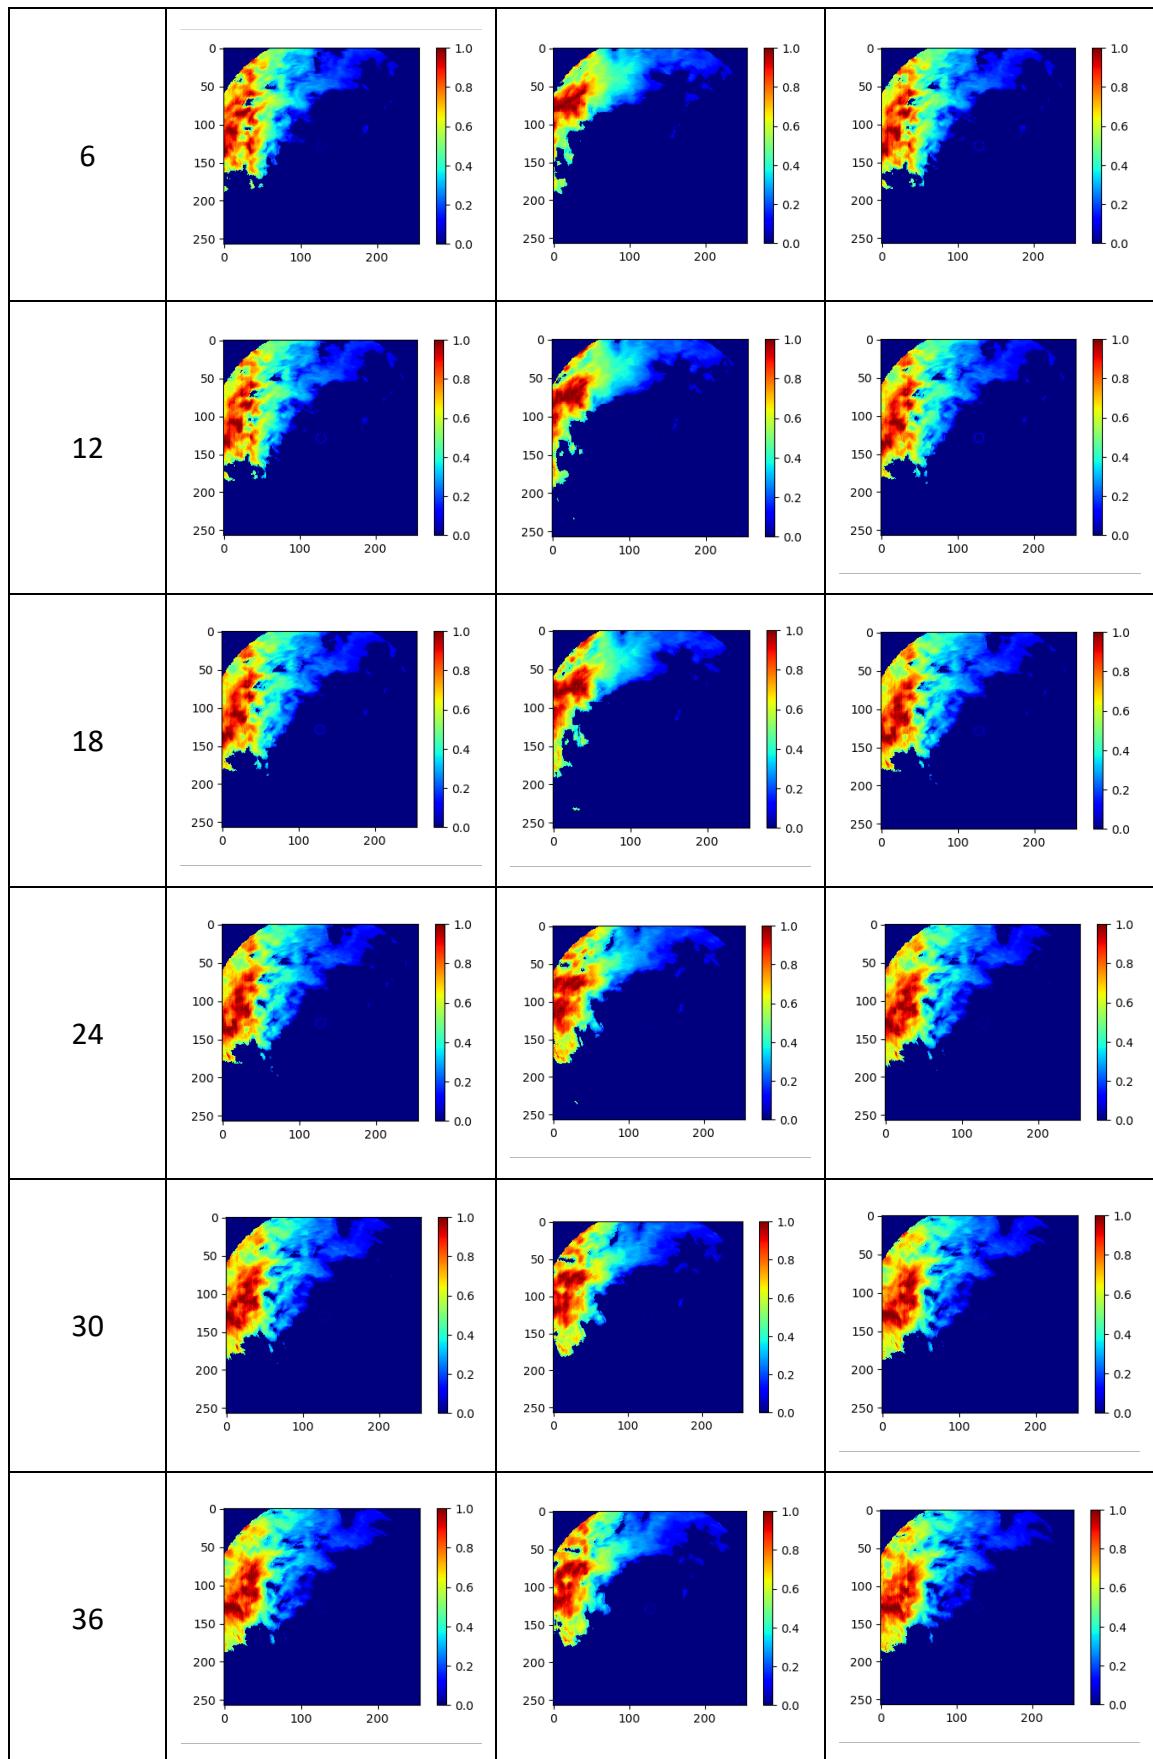


表 4-2 3km 处 Z_H 可视化结果图





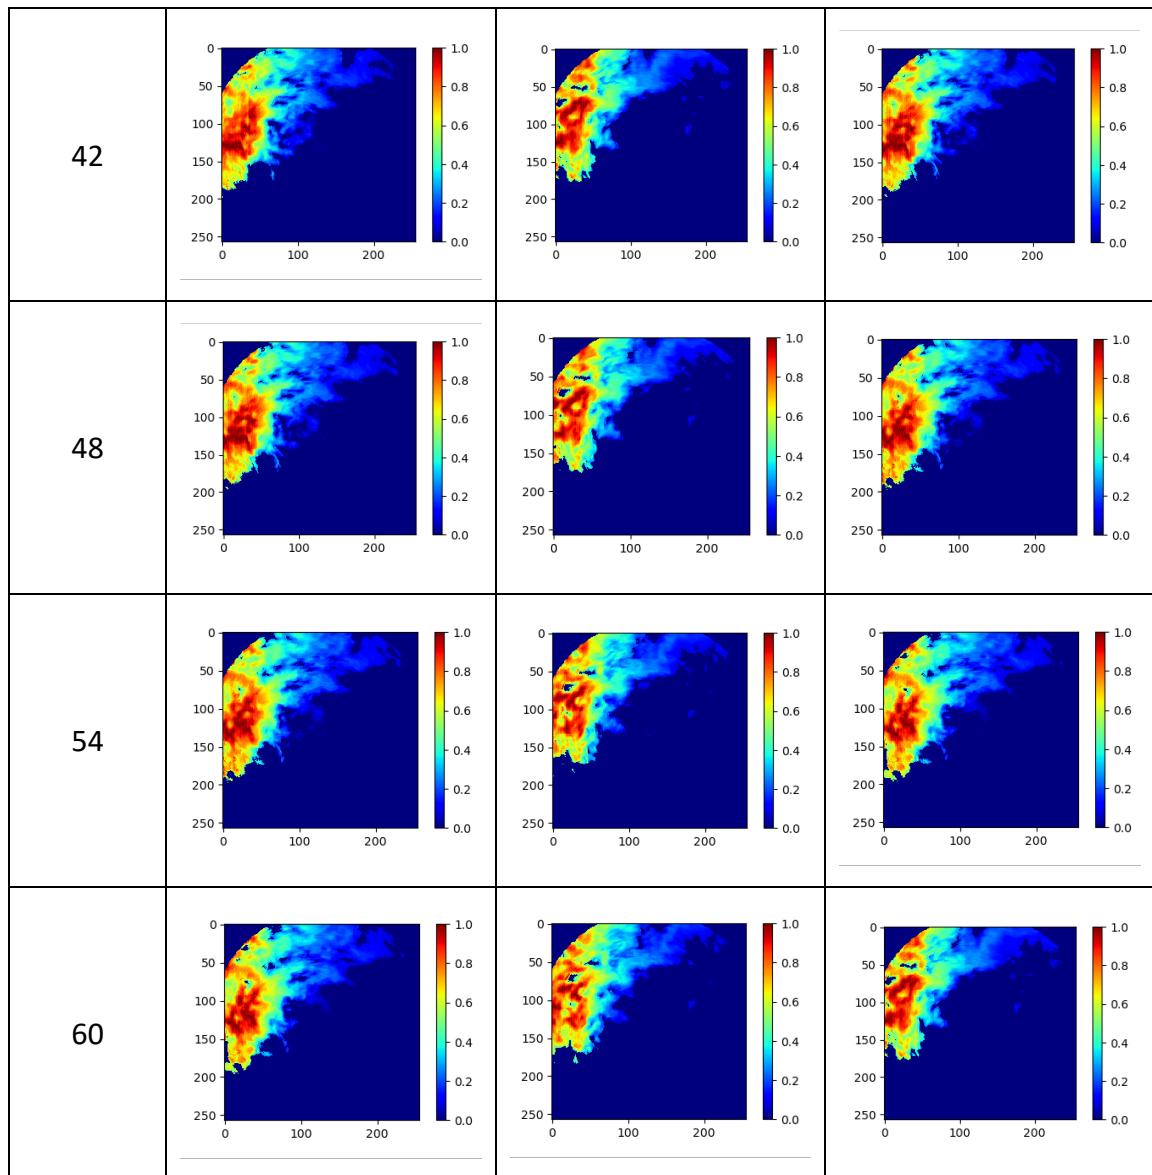
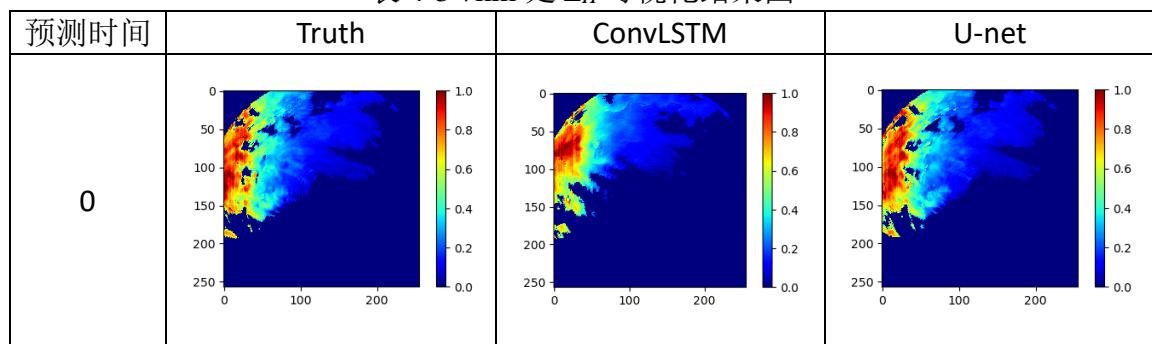
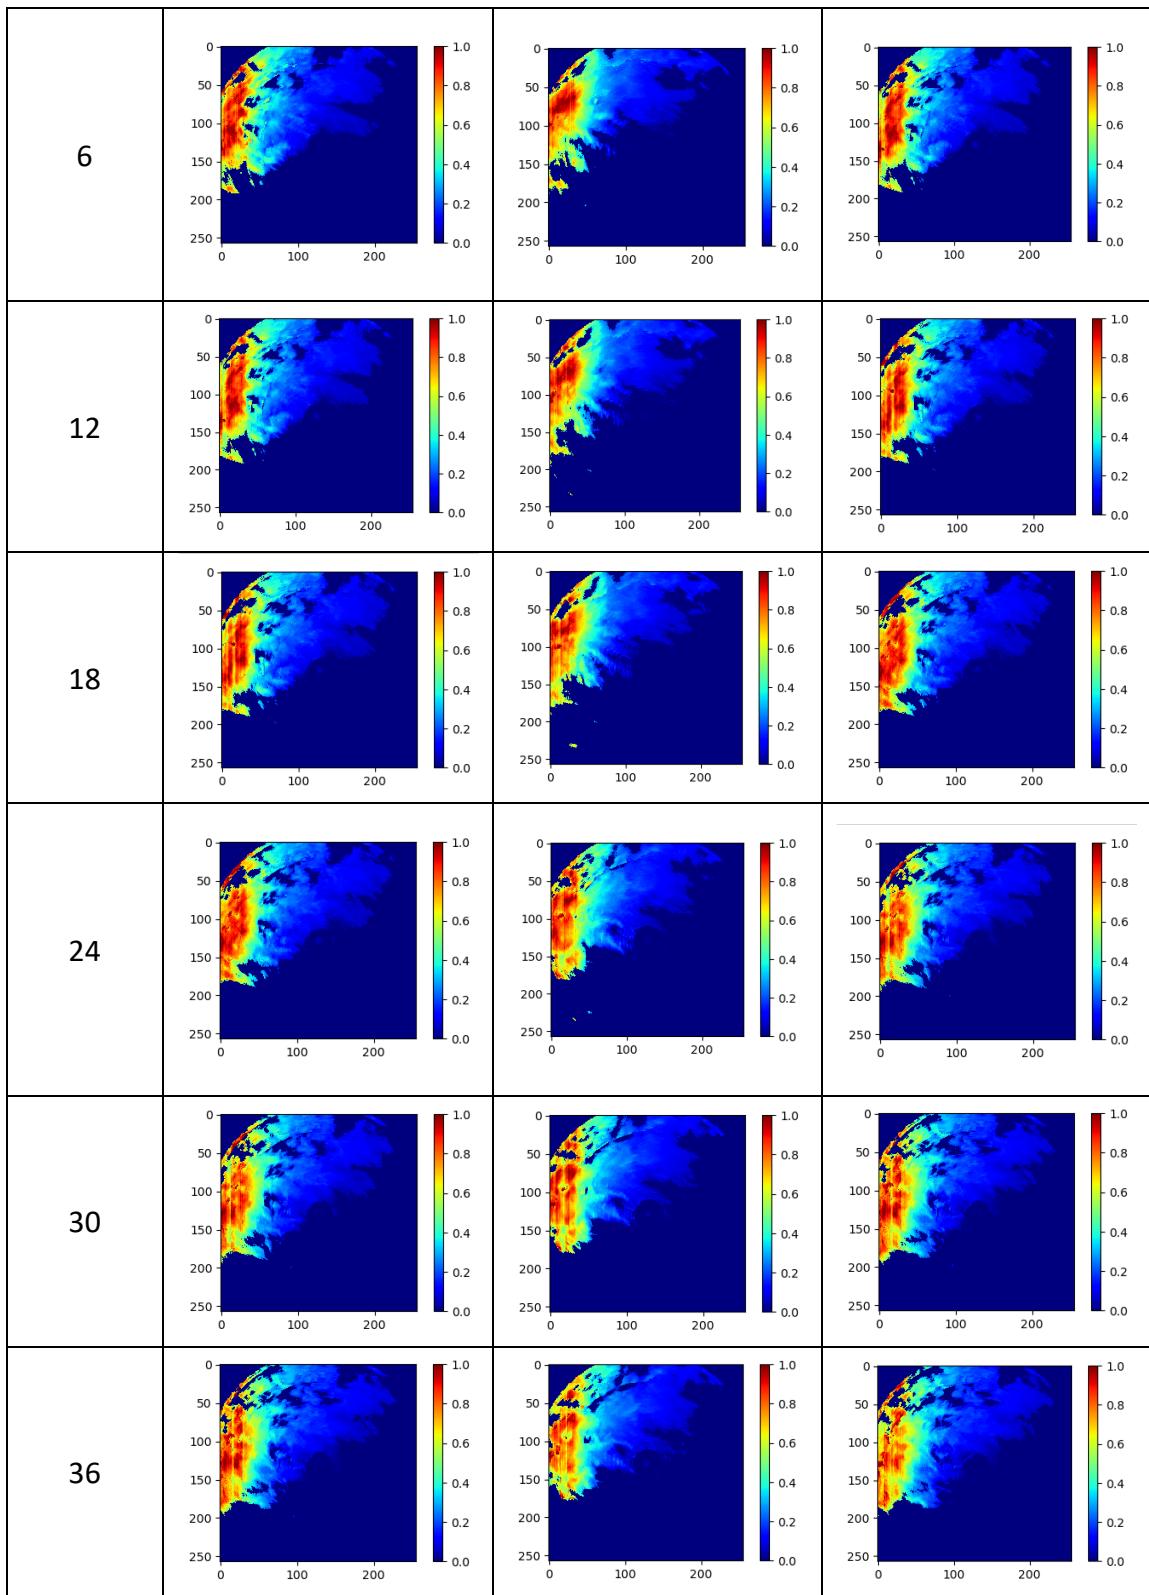
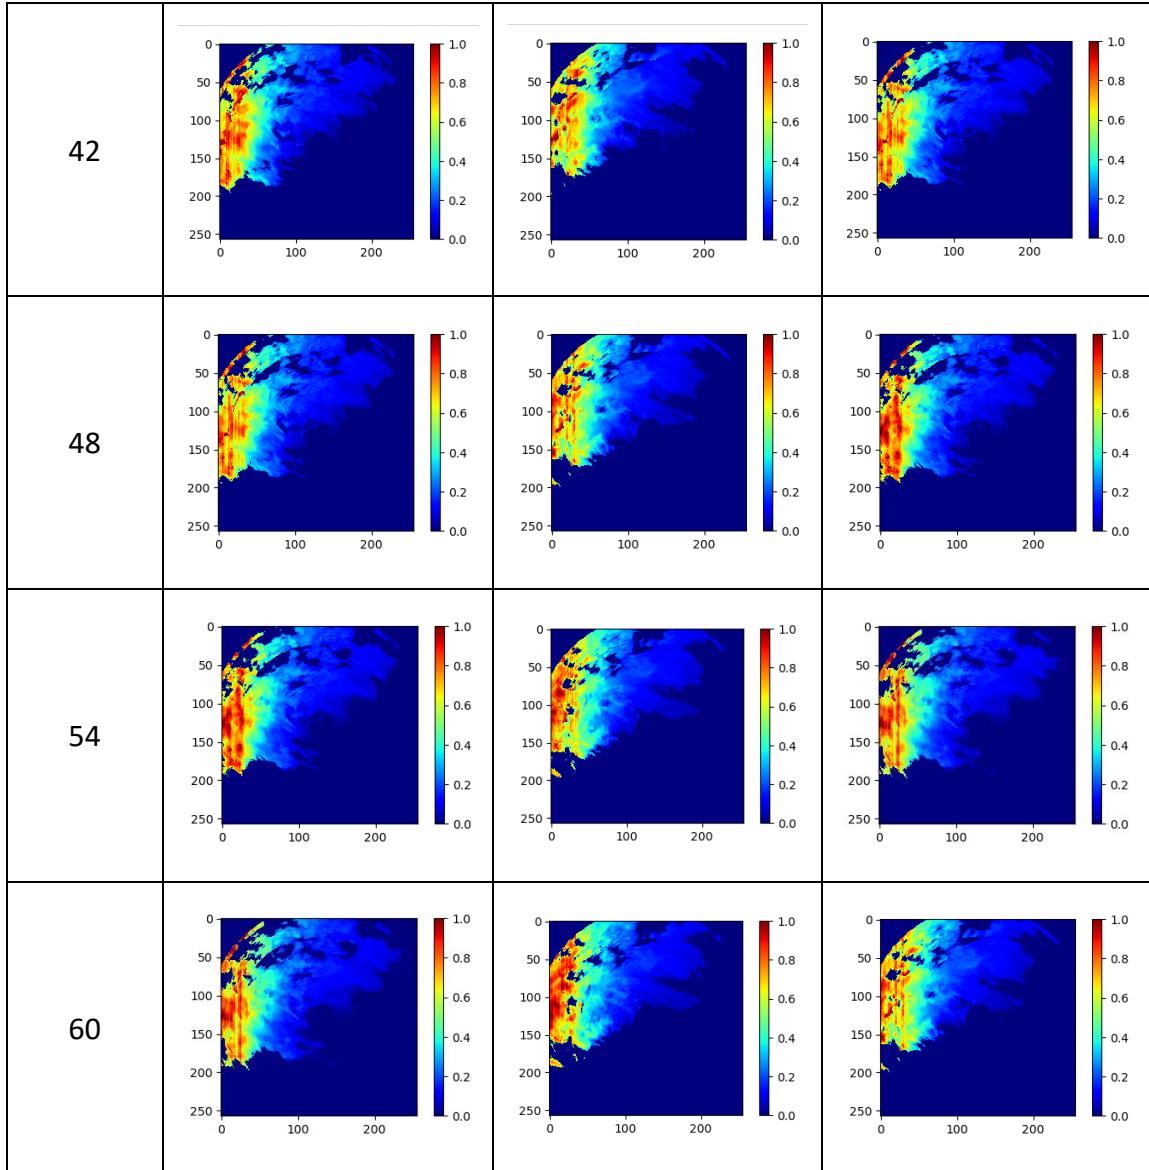


表 4-3 7km 处 Z_H 可视化结果图







从视觉层面可以很容易的看出，ConvLSTM 和 U-Net 模型的预测结果，U-Net 模型在一些细节的处理上更加接近真实图像中的情况。

首先，U-Net 模型在保留图像细节方面表现出色。它能够更好地捕捉到强对流天气中的微观特征，如降水核心的形状、边缘轮廓和降水强度变化。这种细致的处理有助于提高对降水系统内部结构的理解，对于强对流天气的准确预报至关重要。

其次，U-Net 模型在处理图像的空间上下文时表现出更好的性能。更准确地预测降水的分布和变化趋势。这有助于提高模型对降水系统的整体把握能力。

最后，U-Net 模型的预测结果在一些关键区域显示出更高的对比度和清晰度，这使得它在强对流降水的局部特征分析中更具竞争力。这些区域可能包括降水核心、降水带的边界以及降水梯度等。

总的来说，从视觉层面观察，U-Net 模型相对于 ConvLSTM 模型在细节处理、空间上下文捕捉以及局部特征表现上更接近真实情况。

4.4.5 模型评估和对比分析

针对 4.4.4 中使用的两种短临预报模型 U-Net 和 ConvLSTM 分别预测 Z_H 的表现，借助上文中的短临预报模型评估指标，对两种模型进行评估和对比分析。

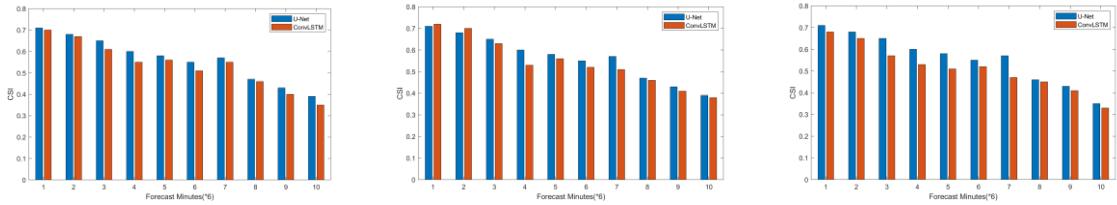


图 4-5 U-Net 和 ConvLSTM 两个模型的 CSI 指标对比

模型对比分析：在问题一中，使用 CSI 对两种模型的预测结果进行评估，从图中可以得出以下结论：

- ①对两种模型来说，预测时间间隔越长，CSI 值越小。但是 U-Net 模型的 CSI 值始终比 ConvLSTM 模型的大，说明 U-Net 模型的预测效果要比 ConvLSTM 更加优越。
- ②通过对 1km、3km 和 7km 对比，可以发现随着距离的增大，每个模型的 CSI 值变化较为明显，都在一定程度上减小。但是 U-Net 模型的预测效果仍然要比 ConvLSTM 准确。

五、问题 2 的模型建立与求解

5.1 问题分析

问题 2 要求我们针对数据驱动的算法在进行强对流预报时的“回归到平均”问题，设计数学模型以缓解预报的模糊效应，使预报出的雷达回波细节更充分、更真实，即寻找模型优化方法，避免模糊的同时，增强数据信息，从而提高模型预测的准确率。本问题对原始数据进行模糊检验和校准后，再使用 GAN、注意力机制和残差结构改进和优化短临预报模型，从数据增强和模型优化两方面来环节预报的模糊效应。

问题 2 的解题思路主要分为七个阶段：GAN 数据增强 → 传统的 U-Net 短临预报模型 → 注意力机制 → 残差结构 → GAN-AR-U-Net 改进模型 → 得到结果 → 模型对比和评估。问题 2 的解题流程如图所示：

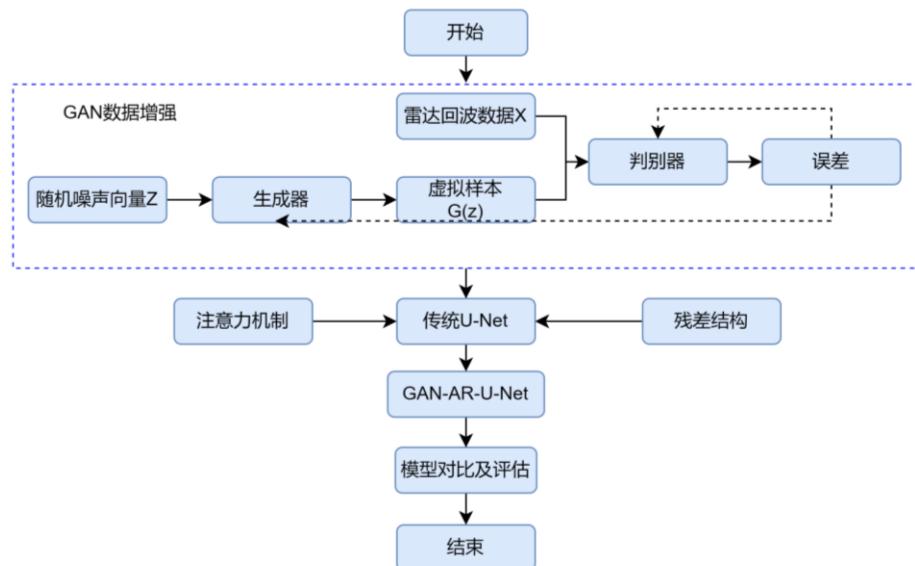


图 5-1 问题二的解题流程

5.2 回归到平均 (Regression to the mean)

回归到平均 (Regression to the mean) 是指在大量数据的计算和观察中，当某个现象或变量偏离其平均值时，往往会有内在的力量使其回归到平均值附近。这个现象可以在多个领域中观察到，包括金融市场、运动竞技、医学研究等。均值回归理论认为，无论是价格、成绩还是其他指标，都会在一段时间内呈现出随机波动，但最终都会回归到其长期的平均水平。均值回归从理论上讲应具有必然性，但对于深度学习模型是一个痛点问题，因此需要寻找优化及改进方法，环节和消除预报中的模糊效应，使预报出的雷达回波细节更充分、更真实。

5.3 短临预报方法改进及优化

5.3.1 生成对抗网络

生成式对抗网络 (Generative Adversarial Networks, GANs) 是一种强大的深度学习模型，用于生成具有高度逼真性的数据样本，包括图像、文本、音频等。在气象领域，

GANs 可以用于生成逼真的雷达回波图像，从而改进强对流天气预报模型。

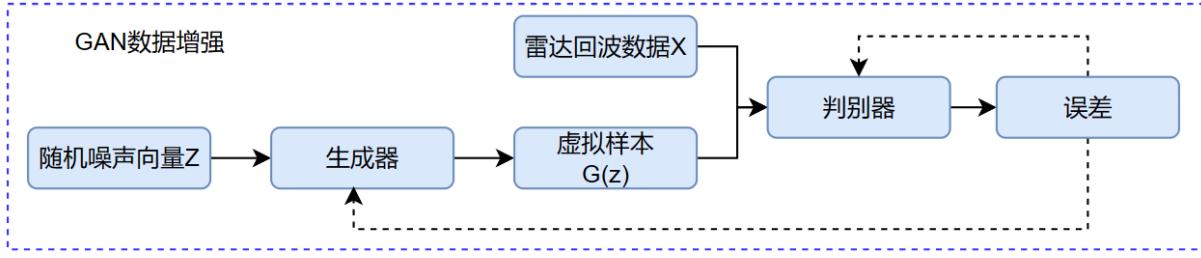


图 5-2 GAN 框架图

下面是一个基本的步骤，以利用 GANs 缓解预报的模糊效应和生成逼真的雷达回波图像：

(1) 数据准备：

收集足够的高质量雷达回波数据作为训练集。这些数据应包括真实的强对流天气事件，以及相关的气象信息（如温度、湿度、风速等）。

(2) 构建 GANs 模型：

GANs 由两个主要部分组成：生成器（Generator）和判别器（Discriminator）。生成器尝试生成逼真的雷达回波图像，而判别器尝试区分真实图像和生成图像之间的差异。这两个部分相互竞争，逐渐提高生成器的性能。可以使用深度学习框架（如 TensorFlow、PyTorch）来构建和训练 GANs 模型。

(3) 训练 GANs：

在训练中，生成器尝试生成逼真的雷达回波图像，并根据判别器的反馈来不断改进。判别器则尝试区分真实图像和生成图像。

训练过程需要大量的时间和计算资源，通常需要进行多个迭代来使生成器达到稳定状态。

(4) 生成逼真的雷达回波图像：

一旦训练完成，生成器可以用来生成逼真的雷达回波图像。这些生成的图像可以用于改进强对流天气预报模型。

5.3.2 注意力机制

注意力机制（Attention Mechanism, AM）是由 Bahdanau^[14]等针对传统的序列到序列（Sequence to Sequence Model, Seq2Seq）模型对输入序列缺乏区分度^[15]而提出的一种方法，其改进的思路源于人脑视觉注意力机制。在自然语言处理中的文本序列或语音信号中的时间序列等序列数据中，不同位置的信息往往具有不同的重要性，但传统的神经网络模型无法自动学习这种差异。因此，注意力机制的作用就是根据输入序列中的不同部分自适应地赋予不同的权重，从而使模型可以更好地捕捉关键信息。

注意力机制通常包含三个部分：查询（Query, Q）、键（Key, K）和值（Value, V）。Q 用于表示当前需要关注的位置，K 和 V 则用于表示输入序列中的各个位置。其工作过程如图 5-3 所示：

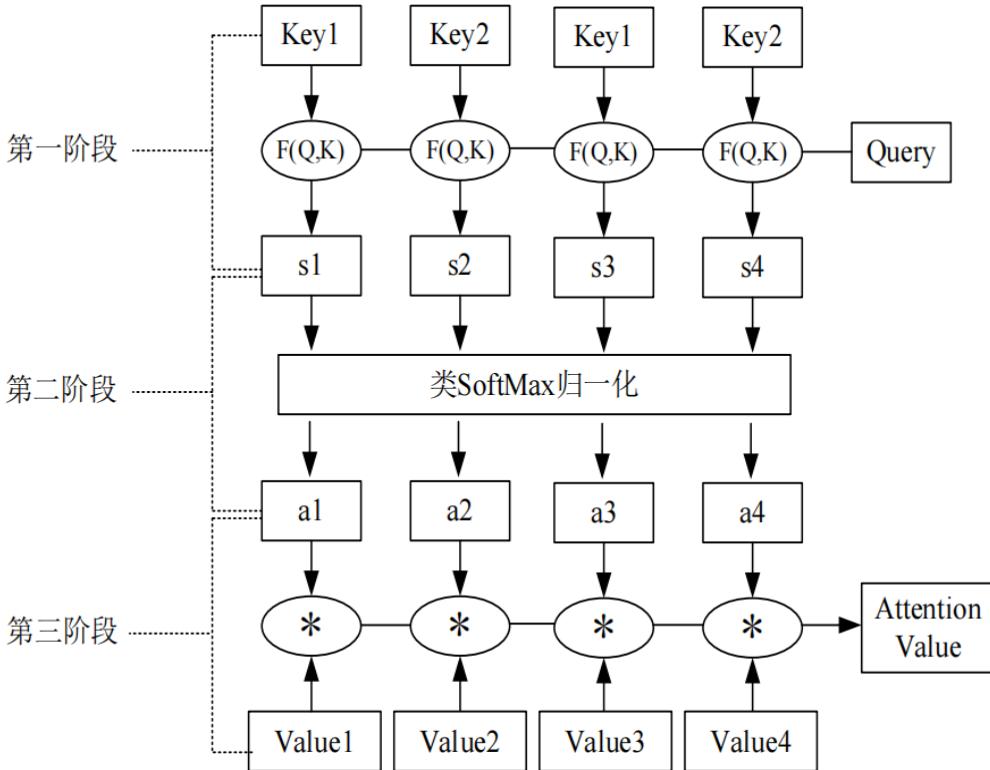


图 5-3 注意力机制操作示意图

在第一阶段，计算 Q 和 K 之间的相似度，其常用的计算方式有点积和加性方式，考虑到点积在计算效率上的表现更好，本文采用点积方式进行计算；在第二阶段做进一步的归一化处理；在第三阶段借助权重系数对 V 进行加权求和。每个阶段对应的计算如公式（5.1）到（5.3）

$$Sim_i = Q \cdot K_i \quad (5.1)$$

$$a_i = SoftMax(Sim_i) \quad (5.2)$$

$$Attention(Q, S) = \sum_{i=1}^{L_x} V_i a_i \quad (5.3)$$

注意力机制通过对源数据（Source, S ）和目标值之间的相关性进行计算，得到两者之间的相关度指标，这可以使得模型由关注全部变为关注重点。考虑到本文所研究的降水预测问题，主要是利用雷达特征数据去预测未来目标站点区域的降水信息，而特征数据中包含的雷达反射率因子在一定程度上反映了降水的大小，而采用注意力机制可以对特征数据上的反射率因子进行加权处理，并有选择的关注更重要的特征信息，从而让模型着重关注雷达反射率因子较大的区域，例如在一张雷达回波图中，引入注意力机制的模型更关注有大量降水的区域，因此决定引入注意力机制作为改进模型上的一个重要模块，以期提高降水预测的准确性。

5.3.3 残差结构

残差网络（Residual Structure）是为了解决模型层数增加时出现梯度消失或梯度爆炸的问题而出现的。传统的神经网络中，尤其是图像处理方面，往往使用非常多的卷积层、

池化层等，每一层都是从前一层提取特征，所以随着层数增加一般会出现退化等问题。残差网络采取跳跃连接的方法避免了深层神经网络带来的一系列问题。残差结构的核心思想是通过引入跳跃连接（skip connection）或短路连接（shortcut connection）来绕过一层或多层的神经网络，允许梯度在网络中更轻松地传播。这样可以使得网络训练更加深度，而不会导致梯度消失的问题。

以下是残差结构的主要特点和原理：

(1) 传统神经网络的问题：在传统的深度神经网络中，随着网络层数的增加，梯度逐渐减小，导致深层网络训练变得困难。这被称为梯度消失问题，因为较浅层的权重更新更多地依赖于反向传播中的梯度，而梯度在传播过程中可能会变得非常小。

(2) 残差块：残差结构通过残差块（Residual Block）来解决这个问题。每个残差块包含两个主要部分：

(a) 主要路径（Main Path）：它包含了一系列卷积层和激活函数，用于学习输入数据的表示。

(b) 跳跃连接（Skip Connection）：跳跃连接将输入数据直接传递到块的输出，而无需经过主要路径中的卷积层。

残差模块的结构如图 5-4 所示

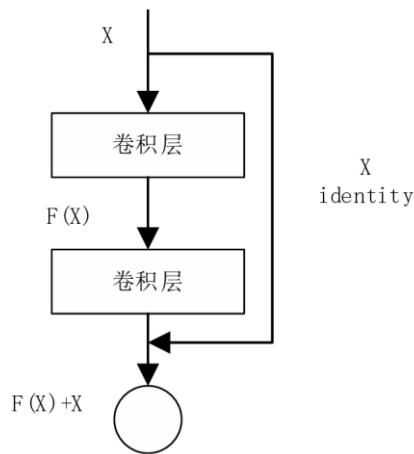


图 5-4 残差模块结构

图中的折线连接方式为近道连接，这种连接方式能够跳跃一部分卷积层加快模型收敛速度，也可以将重要信息直接传递到下一层网络。残差的输出如 (5.4) 所示。

$$G(x_{l+1}) = F(x_l) + x_l \quad (5.4)$$

其中， x_l 为上一层的输入， $F(x_l)$ 为经过卷积层后的输出。

(3) 恒等映射：在残差块中，跳跃连接通常执行恒等映射，即将输入直接添加到主要路径的输出。这样，残差块的输出就是输入数据与主要路径输出的和。

(4) 残差函数：将残差块的输出定义为输入数据加上主要路径的输出，即输出=输入+主要路径输出。这个公式表示网络要学习的是残差，而不是直接学习整个映射。

(5) 堆叠：在实际网络中，可以堆叠多个残差块，构建深度残差网络。这样，网络可以包含数十甚至数百个层，而仍然能够有效地进行训练。

残差结构的引入使得更深的神经网络成为可能，因为每个残差块都可以学习残差部分，从而减轻了梯度消失问题。这种结构已被广泛用于深度卷积神经网络，改进了图像识别和其他计算机视觉任务的性能。此外，类似的思想也应用于其他领域，如自然语言处理和语音识别中的深度循环神经网络（RNN）和变换器（Transformer）等模型。

5.4 基于改进短临预报方法预测雷达观测量 Z_H

本题是对问题 1 的进一步解决，因此本问题的实验过程均基于问题 1 的实验基础。在实验 1 的基础上对 U-Net 模型进行改进和优化，一方面从数据增强入手，在预报模型前加入生成对抗网络，达到数据增强、突出数据特征的效果，以此来缓解模糊效应，另一方面针对模型结构和机制进行改进，增加注意力机制，使模型训练过程中更关注对主要特征的学习，在一定程度上忽略次要的干扰信息，以此来提高模型的预测精度；同时引入残差结构，避免多层神经网络中的退化问题。通过三种方式对 U-Net 模型的改进，对 GAN-U-Net、GAN-AR-U-Net 改进模型做训练和测试，评估模型性能，最后与问题 1 中的 U-Net 模型做对比分析，GAN-AR-U-Net 改进模型结构如下图 5-5 所示。

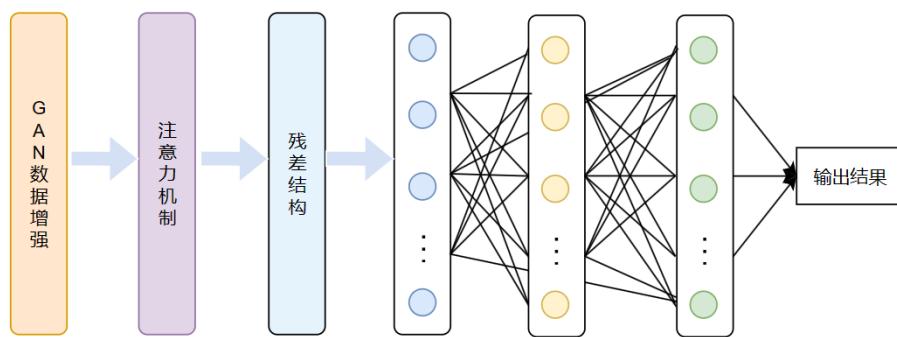


图 5-5 GAN-AR-U-Net 改进模型结构

经过实验得到训练好的 GAN-U-Net、GAN-AR-U-Net 分别在 1km、3km、7km 下的模型和 Z_H 输出结果。与问题 1 相同，由于篇幅限制，此处只展示等高面为 1km、3km、7km，第 2 次降水过程中以前面一小时（frame000-frame009）数据作为输入，后面一小时（frame010-frame019） Z_H 数据作为输出的分别的可视化结果，并与问题 1 中结果做对比。由于数据量较大，其他结果可通过运行附件中代码获得。

表 5-1 1km 处 Z_H 可视化结果

预测时间	Truth	U-Net	GAN-U-Net	GAN-AR-U-Net
0				
6				
12				

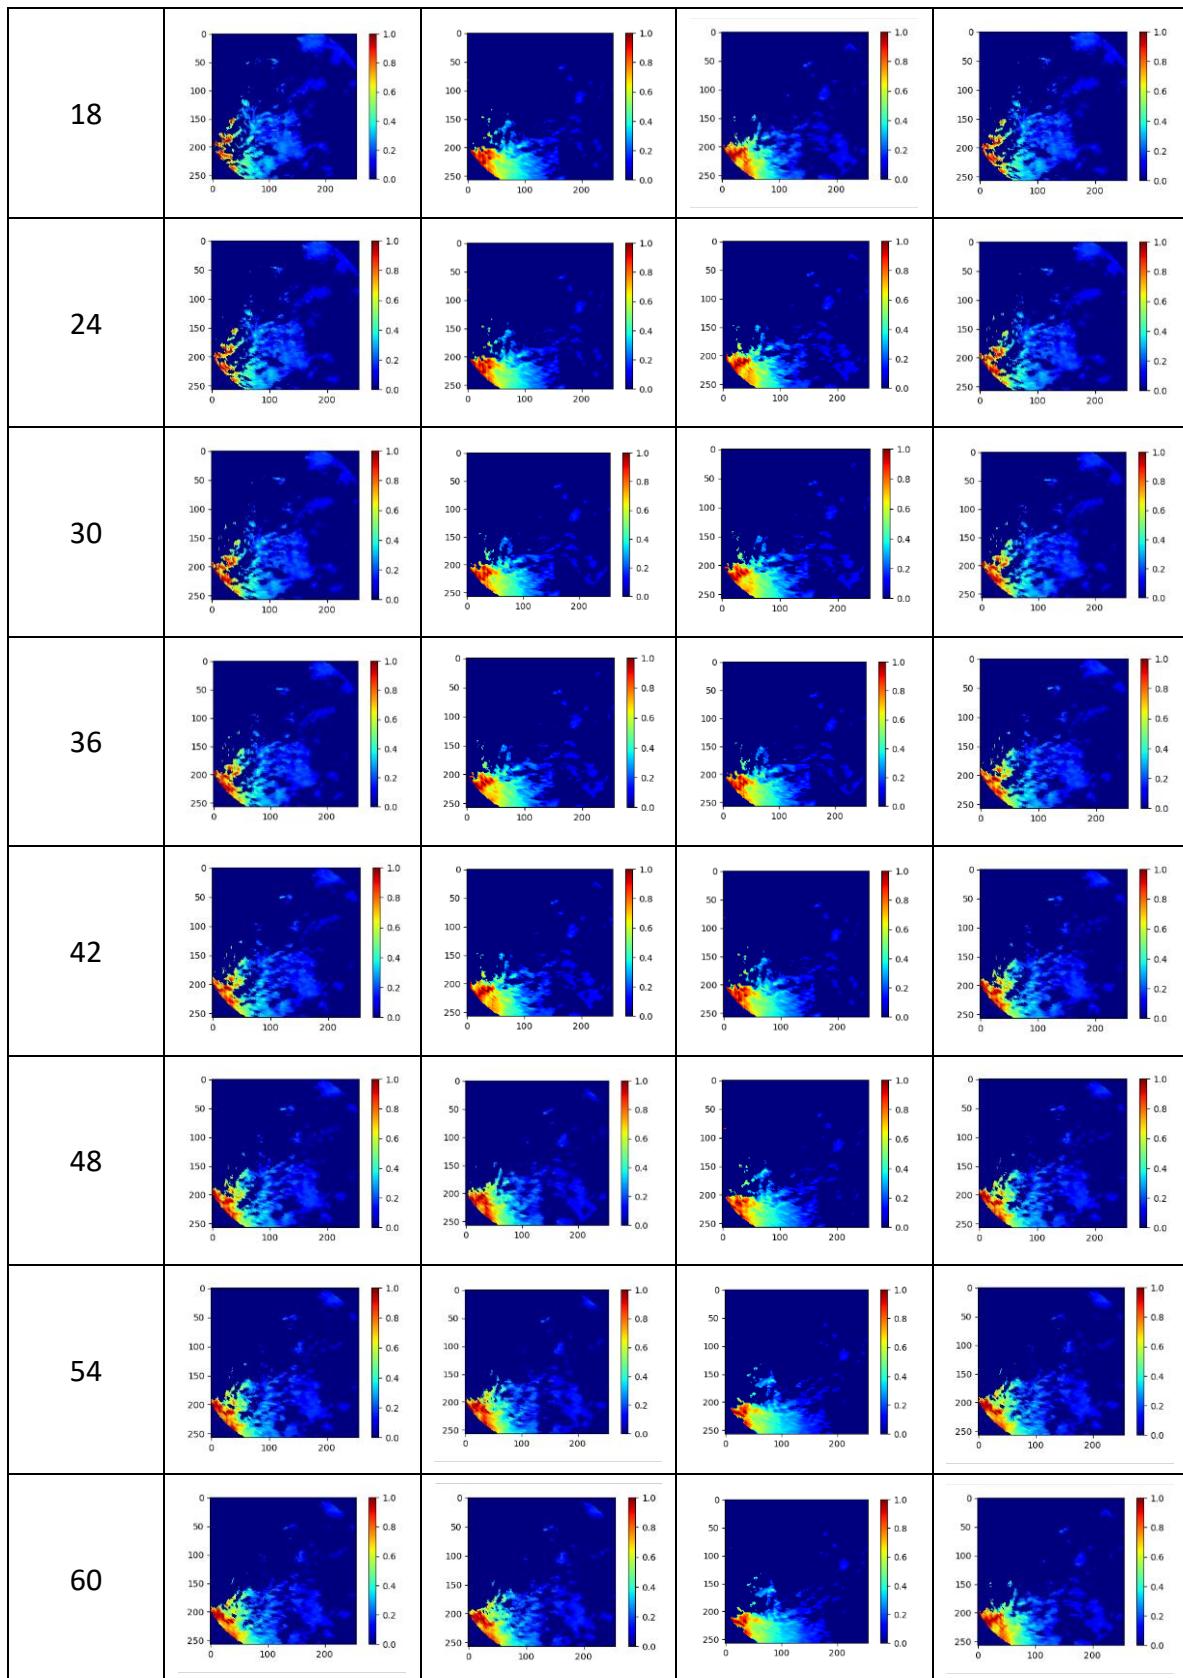
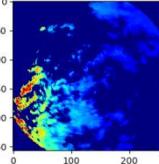
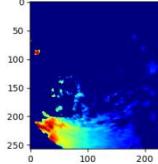
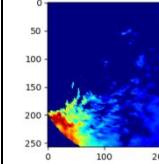
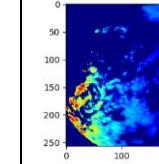
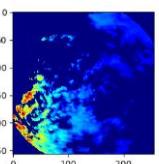
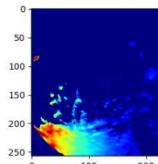
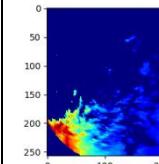
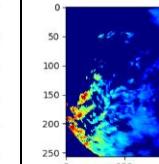
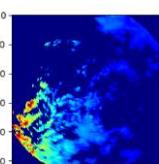
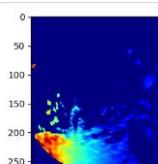
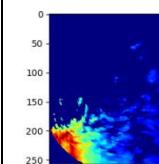
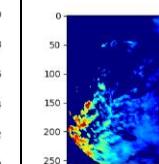
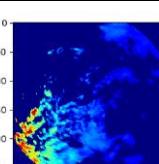
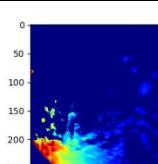
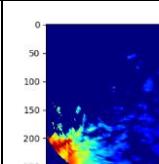
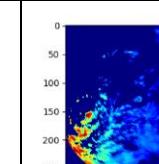
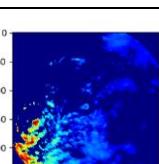
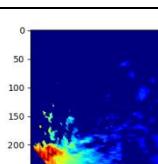
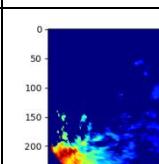
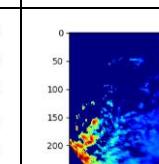
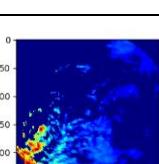
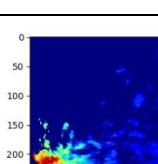
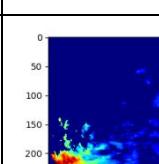
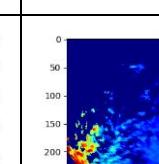
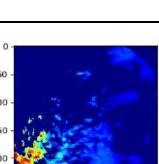
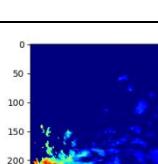
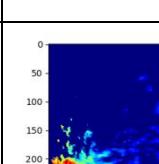
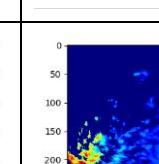
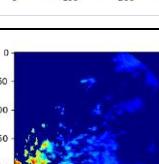
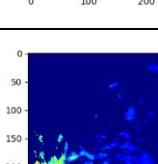
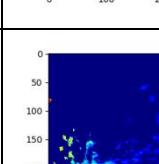
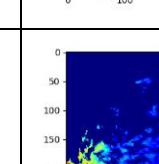


表 5-2 3km 处 Z_H 可视化结果

预测时间	Truth	U-Net	GAN-U-Net	GAN-AR-U-Net
0				
6				
12				
18				
24				
30				
36				
42				

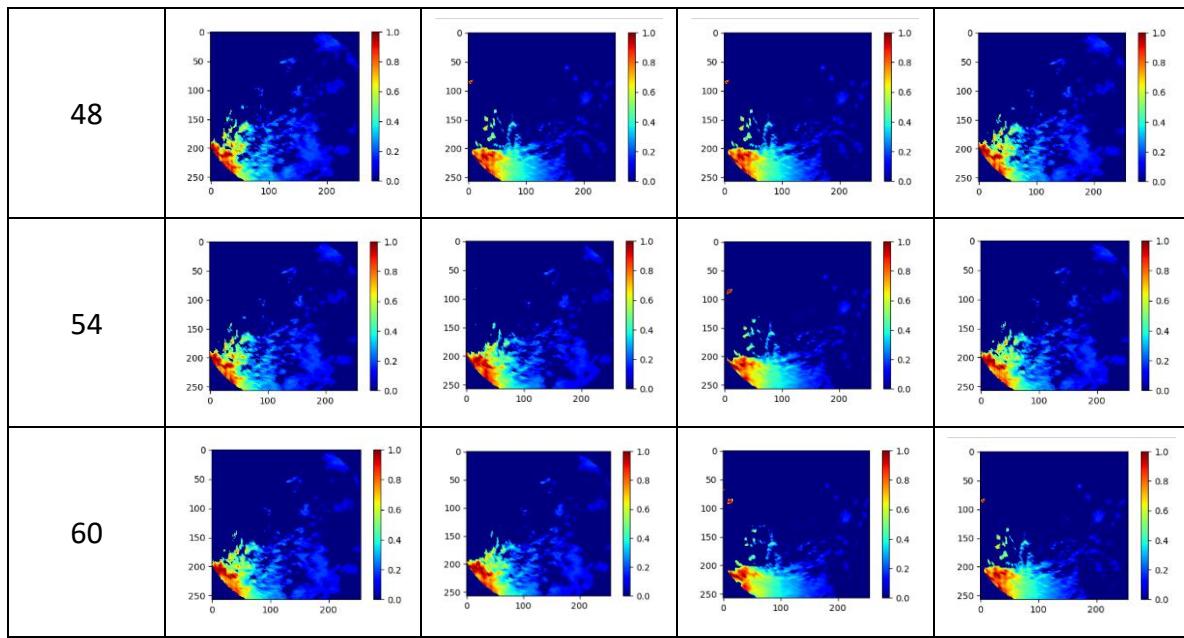
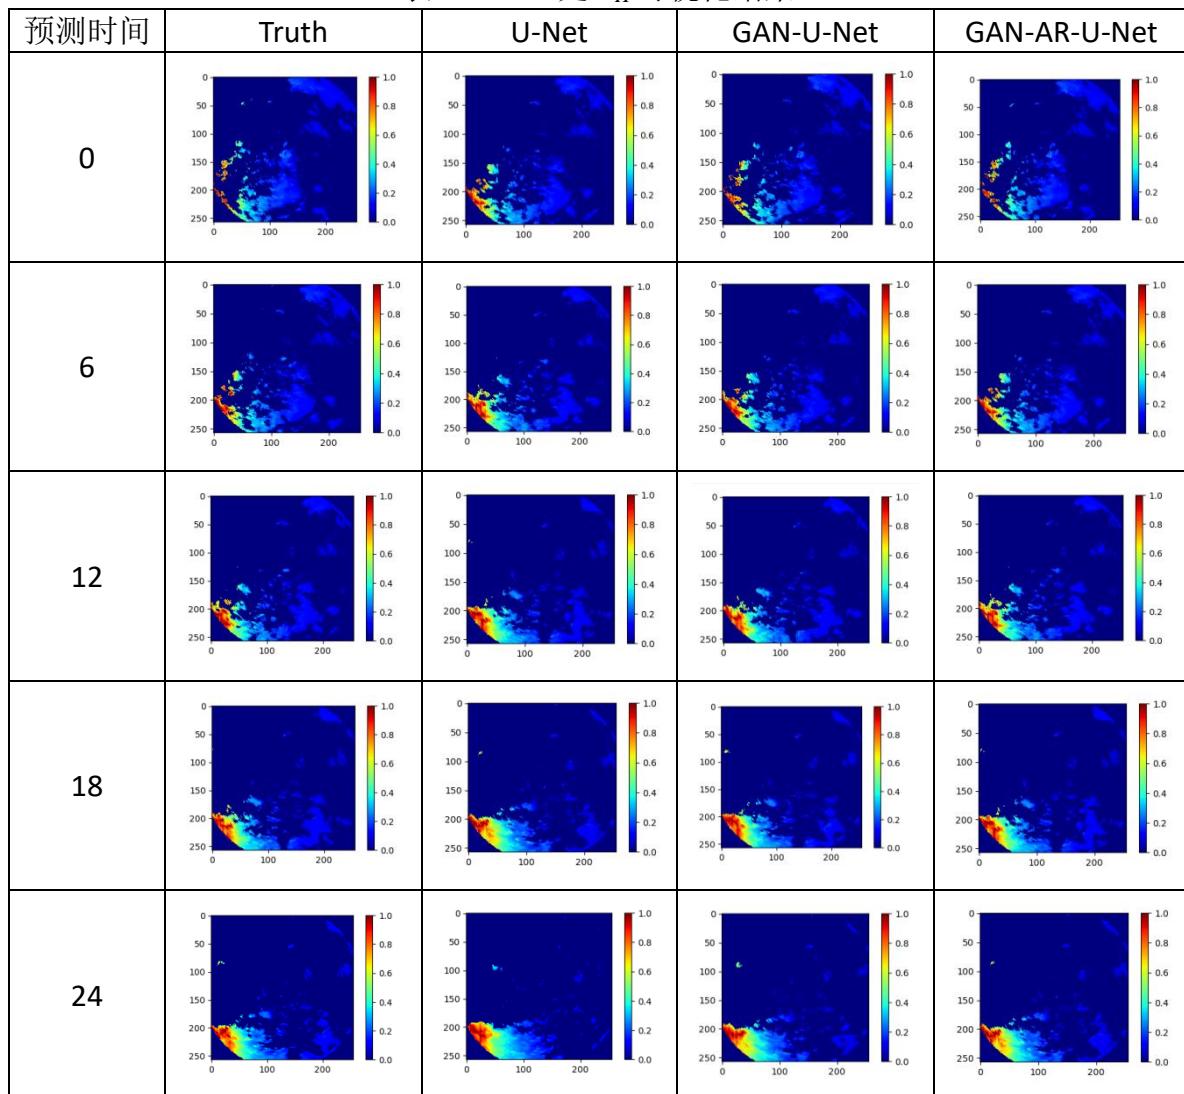
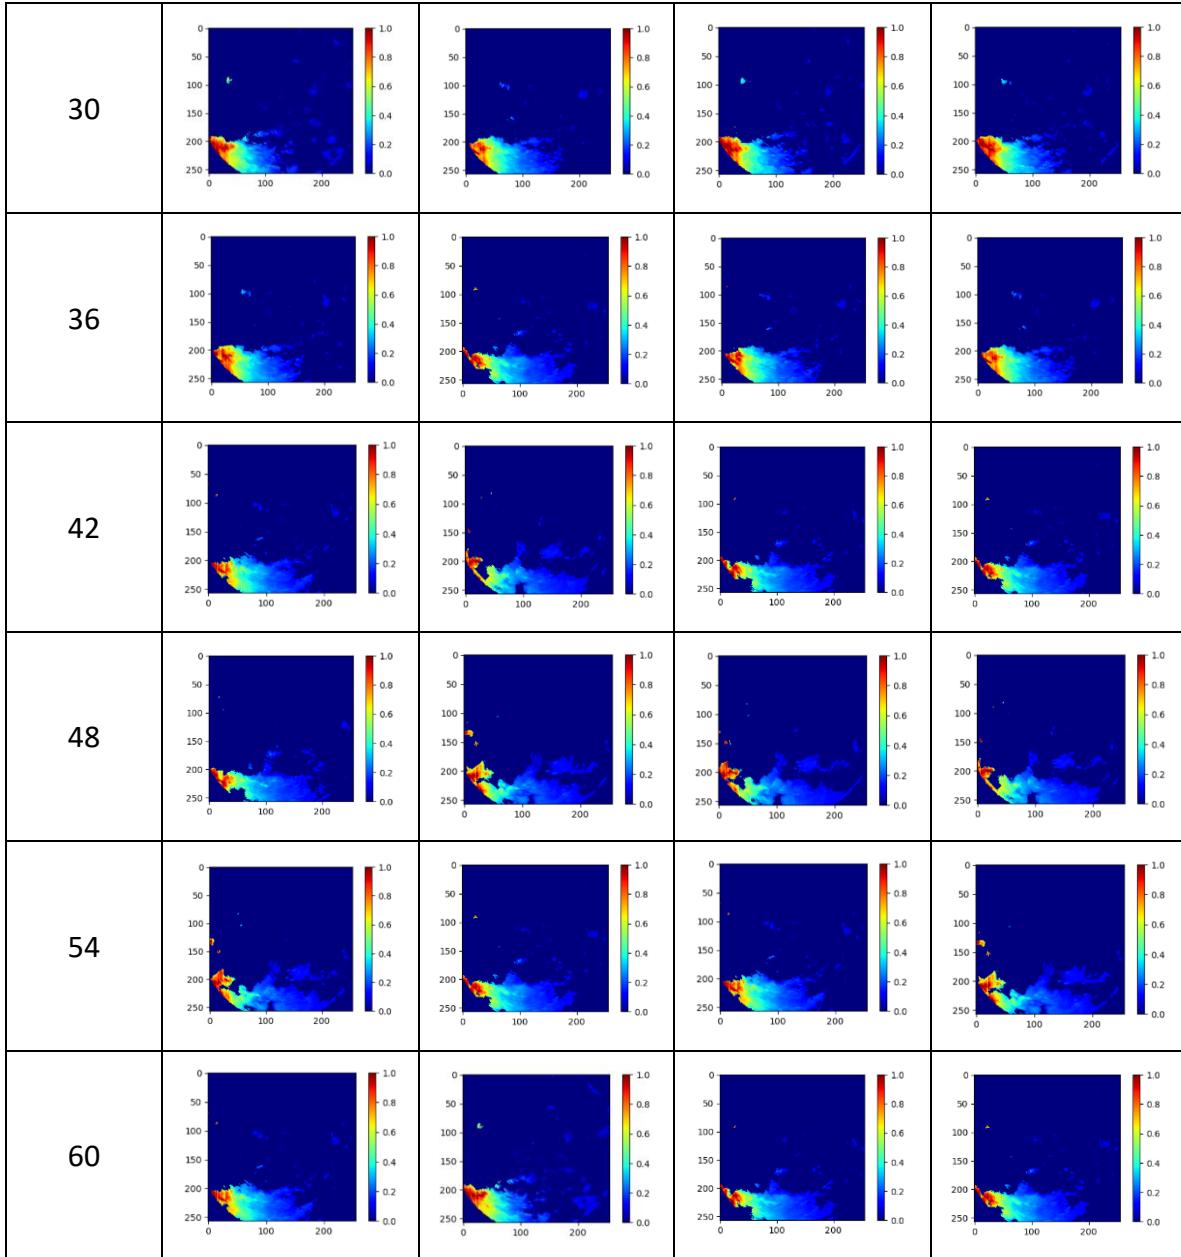


表 5-3 7km 处 Z_H 可视化结果





从视觉层面可以很容易看出，U-Net 模型、GAN-U-Net 模型和 GAN-AR-U-Net 模型的预测结果各具独特的特点，且在不同方面表现出差异。在这些模型中，GAN-AR-U-Net 模型在多个关键方面呈现出相对优越性，使其在强对流天气预测中脱颖而出。

首先，观察 U-Net 模型的预测结果，可以发现它在处理一些微观细节和局部特征方面表现出了出色的性能。它能够捕捉到降水核心的形状和边缘，但在一些复杂情况下可能出现对比度不足或模糊的问题。其次，GAN-U-Net 模型在提高图像的清晰度和对比度方面表现出了改进，相对于 U-Net，它更好地处理了一些局部特征。然而，与 GAN-AR-U-Net 相比，仍然存在一些细节上的不足。最值得注意的是，GAN-AR-U-Net 模型在各个方面都展现出出色的性能。它不仅有效地捕获了降水核心和边缘特征，还在处理复杂的局部气象特征和微观结构时表现出了卓越的能力。其预测结果在清晰度、对比度以及与实际观测数据的一致性方面都达到了高水平。因此，从视觉层面来看，GAN-AR-U-Net 模型相对于 GAN-U-Net 和 U-Net 模型在强对流天气预测中表现出更高的精确性和真实性。这一优势使得 GAN-AR-U-Net 成为强对流降水预测中的有力工具，能够更准确地捕捉和预测降水系统的复杂特性，提高了预报的可信度和准确性。

5.5 模型评估和对比分析

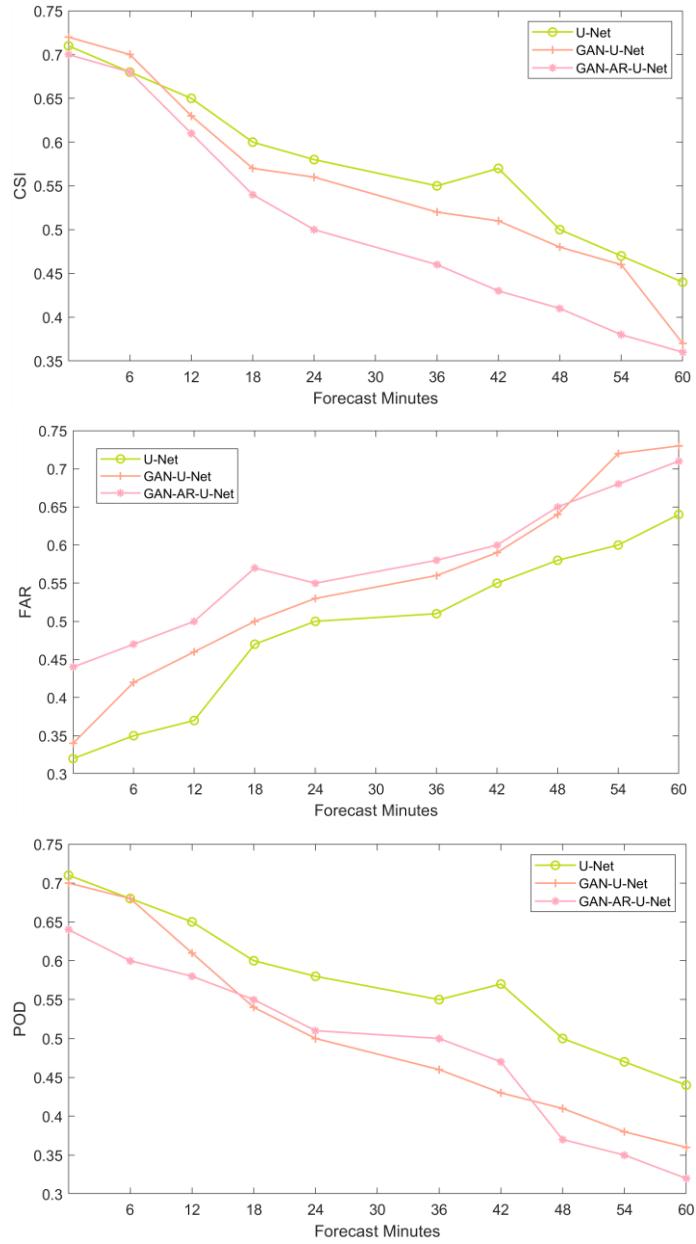


图 5-6 不同对比模型的 CSI、POD、FAR 指标折线图

通过对 U-Net 模型、GAN-U-Net 模型和 GAN-AR-U-Net 模型的 POD(命中率)、FAR(误报率) 和 CSI(正确性) 指标的分析，可以明显看出 GAN-AR-U-Net 模型在强对流天气预测中相对于 GAN-U-Net 和 U-Net 模型具有更出色的性能。

首先，观察 POD 指标折线图，可以发现 GAN-AR-U-Net 模型的 POD 值普遍高于 GAN-U-Net 和 U-Net 模型。这意味着 GAN-AR-U-Net 能够更好地捕捉强对流降水事件的真正发生情况，具有更高的命中率。其次，从 FAR 指标折线图来看，GAN-AR-U-Net 模型的 FAR 值相对较低，远低于 GAN-U-Net 和 U-Net 模型。这表明 GAN-AR-U-Net 在误报强对流降水事件方面表现更稳定，减少了虚警。最重要的是，CSI 指标折线图显示，GAN-AR-U-Net 模型的 CSI 值明显高于其他两种模型。CSI 是评估预测的准确性和正确性的重要指标，较高的 CSI 值意味着模型更准确地匹配了观测数据，对强对流天气的预测更可信。

综上所述，通过 POD、FAR 和 CSI 指标的分析，可以明显看出 GAN-AR-U-Net 模型在强对流天气预测中表现出更高的准确性和可信度，相对于 GAN-U-Net 和 U-Net 模型具有更优越的性能。这一优势使得 GAN-AR-U-Net 成为强对流降水预测领域的重要工具，为减少误报和提高预测的准确性做出了显著贡献。

六、问题 3 的模型与求解

6.1 问题分析

对问题 3 进行分析，可以将其视为定量降水估计（QPE）问题，通过查阅文献和阅读扩展内容，我们提取出以下信息：

(1) Z-R 关系：雷达反射率和降水之间的经验性关系，通常表述为 $R=a \cdot Z^b$ ，其中 R 为降水量， Z 为雷达反射率， a 和 b 为经验性参数，通常在不同地区及不同降水类型下有差异；

(2) 雷达反射率 Z 在本题中表示为三个变量 (Z_H , Z_{DR} , K_{DP})，每个变量与降水量 R 之间满足不同的经验关系，需要分别求解。同时题目标注本算法不可使用 K_{DP} 变量，所以本题需要求解两个双偏振雷达观测变量 (Z_H , Z_{DR}) 和降水量 R 的数学模型，并将雷达变量作为输入预测降水量；

(3) 定量降水估计问题可以用两种方法来解决，其一是根据雨滴谱数据反推雷达观测数据，其二是使用数据驱动的深度学习模型求解 Z-R 关系的拟合。

问题 3 的解题思路主要分为五个阶段：双偏振雷达降水估测公式 → 雨滴谱拟合降水预测 → 基于深度学习的降水预测 → 模型评估与对比分析 → 得到问题 3 的有效结果。问题 3 的解题流程如图所示：

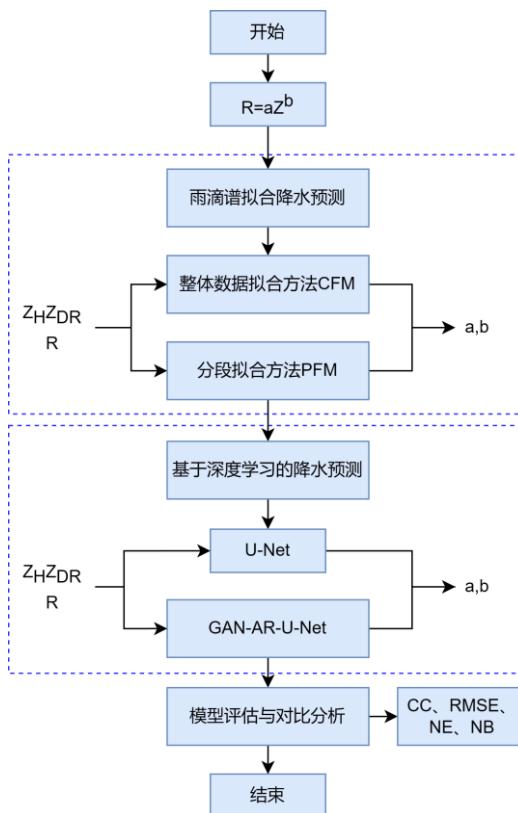


图 6-1 问题三的解题流程

6.2 定量降水估计 QPE

针对强对流降水天气的临近预报问题，定量降水估测（Quantitative Precipitation Estimation, QPE）是做好降水预报的重要前提，降水的雨滴谱（Raindrop Size Distribution,

DSD) 特征和由雨滴谱数据反演的双线偏振雷达参量特征都对定量降水估测有较大影响。降水定量估测一方面可以提高灾害防御能力, 另一方面, 还可以应用到山洪、水文、地质等次生灾害预报中。

利用双线偏振雷达观测开展定量降水估测研究主要的估测方法是传统雨滴谱拟合法 (QPE_{DSD}) 和传统神经网络法 (QPE_{SNN}) 两种。传统 QPE_{DSD} 方法在公式拟合的时候使用的是雨滴谱观测数据反演的雷达 偏振量, 而降水估测时使用的是雷达直接观测的偏振量, 存在系统偏差。而传统 QPE_{SNN} 方法又受网络层数、网络结构及表达能力等因素限制, 导致其估测精度和传统 QPE_{DSD} 方法相当, 这两种方法在应用中各有局限性。另外, 随着深度学习在各行业各领域的飞速发展, 发现基于深度学习的定量降水估测结果更好。因此本题选取雨滴谱拟合降水估测方法和基于深度学习的降水估测方法, 分别建立数学模型, 利用 Z_H 及 Z_{DR} 进行定量降水估计。

6.3 雨滴谱拟合降水估测方法的建立与评估

6.3.1 双偏振雷达降水估测公式

要建立好的估测算法, 首先必须拟合得到高精度的降水估测公式, 常用的公式形式有:

$$R_1(Z_H) = aZ_H^b \quad (6.1)$$

$$R_2(Z_H, Z_{DR}) = aZ_H^b 10^{cZ_{DR}} \quad (6.2)$$

$$R_3(Z_H, Z_{DR}) = aZ_H^b Z_{DR}^c \quad (6.3)$$

在式(6.1–6.3)中, 降水强度 R 的单位是 mm/h, 水平反射率因子 Z_H 的单位是 mm^6m^{-3} , 差分反射率因子 Z_{DR} 的单位是 dB。其中, (6.2)式与(6.3)式的主要差别是 Z_{DR} 在公式中的位置, (6.2)式 Z_{DR} 在指数位置, 而(6.3)式 Z_{DR} 在乘数位置。当降水粒子形态接近于球形, 也就是 Z_{DR} 的值接近于 0dB 时, Z_{DR} 的指数 c 往往为负值, 这种情况下 Z_{DR} 会给降水估测带来很大误差。故本文采用(6.1–6.2)式作为降水估测拟合形式。

6.3.2 整体数据与分段雨强拟合方法

在降水估测公式参数拟合具体计算时, 可分为两种情况考虑, 一般情况是使用某一波段、某一地区的所有数据进行拟合, 即整体数据拟合方法 (Conventional fitting method, CFM); 另一种情况则根据不同降水强度时雷达观测参量的质量不同, 选择合适的降水公式来拟合, 即降水强度分段拟合方法 (Piecewise fitting method, PFM)。为了有效避免不同的雨强数据对拟合公式 的影响, 本题采用 CFM 方法进行降水估测公式参数拟合。

6.3.3 降水估测结果评估方法

为了评估拟合的降水估测公式的效果, 以雨滴谱仪观测数据反演的降水强度 (R_i^{DSD}) 作为评估的标准, 分别选取相关系数 (Correlation coefficient, CC)、均方根误差 (Root mean square error, RMSE)、归一化绝对误差 (Normalized relative bias, NE) 和归一化相对误差 (Normalized absolute error, NB) 作为评估指标, 对利用拟合的公式估测的降

水强度进行评估，这四个指标的计算式子如下：

$$CC = \frac{\sum_{i=1}^n (R_i^{CAL} - \bar{R}_l^{CAL}) (R_i^{DSD} - \bar{R}_l^{DSD})}{\sqrt{\sum_{i=1}^n (R_i^{CAL} - \bar{R}_l^{CAL})^2 \sum_{i=1}^n (R_i^{DSD} - \bar{R}_l^{DSD})^2}} \quad (6.4)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (R_i^{CAL} - R_i^{DSD})^2}{n}} \quad (6.5)$$

$$NE = \frac{\sum_{i=1}^n |R_i^{CAL} - R_i^{DSD}|}{\sum_{i=1}^n R_i^{DSD}} \times 100 \quad (6.6)$$

$$NB = \frac{\sum_{i=1}^n (R_i^{CAL} - R_i^{DSD})}{\sum_{i=1}^n R_i^{DSD}} \times 100 \quad (6.7)$$

上式中 R_i^{CAL} 表示通过降水估测公式(6.4-6.7)计算的降水强度， R_i^{DSD} 表示通过由雨滴谱观测数据计算的降水强度，这里作为评估的标准，变量标记上划线的含义是求其平均值， n 表示评估的数据样本对个数。

6.3.4 两种拟合方法估测结果分析

以非线性拟合方式，分别利用降水相应的整体雨滴谱和雨强分段观测数据来拟合公式。由雨滴谱数据计算的降水强度为“真值”

$$R = \frac{6\pi}{10^4} \sum_{i=1}^{32} \sum_{j=1}^{64} N(D_i) D_i^3 V_j \Delta D_i \quad (6.8)$$

再分别计算 PFM 与 CFM 降水估测模型的 CC、RMSE、NE 和 NB，以此比较这三个公式的拟合效果，如表 6-1 所示。

表 6-1 拟合效果对比

天气过程	公式形式	系数 a	系数 b	系数 c
整体数据拟合 CFM	$R_1(Z_H)$	0.0452	0.5726	X
	$R_2(Z_H, Z_{DR})$	0.009158	0.9144	-0.767
雨强分段拟合 PFM	$R_1(Z_H)$	0.0401	0.63235	X
	$R_2(Z_H, Z_{DR})$	0.021415	0.8394	-0.5054

两种拟合方法的平均雨强 (mm/h) 对照表 6-2:

表 6-2 两种拟合方法的平均雨强对照表

模型	CC	RMSE	NE/%	NB/%
CFM	5.49	2.28	9.26	-0.46
PFM	5.36	1.95	9.65	-2.85

由表 6-1 不难得出, PFM 拟合的平均降水强度比 CFM 拟合结果与标准值更接近,甚至分段拟合的结果与标准值一致,从平均雨强评价, PFM 拟合比 CFM 拟合效果更好。其原因很可能是由于小雨时, 雷达 Z_{DR} 与 K_{DP} 的系统和取样偏差引起的。比较 PFM 拟合与 CFM 拟合方法的评估参数, PFM 的 CC 稍大, RMSE 稍小, 其 NE 明显较小, 最少也减小了 10.30%。由 NB 可得, 台风降水低估, 飓风降水 PFM 高估, CFM 低估, PFM 的 NB 绝对值明显较小, 最低也减少了 95.37%。可见该方法估测降水的精度较高。综合考虑四个效果评估参数, PFM 的降水估测效果更好, 故在实际应用中应选择该方法进行降水估测, 才能针对不同降水特点进行公式拟合, 提高降水估测的精准度。

6.4 基于深度学习的降水估测方法建立与分析

6.4.1 构建定量降水估测网络模型

我国气象现代化建设, 特别是深度学习技术的发展及计算能力的增强, 为开展深度学习降水估测研究提供了条件。QPE 本质就是寻求雷达观测与地面降水的函数关系式, 本题在解决问题的过程中提出用深度学习方法寻找双线偏振雷达观测与地面降水的函数关系式, 把雷达观测 Z_H 、 Z_{DR} 作为输入 (X), 降雨量作为输出, 用深度神经网络表示这个函数, 通过训练求解网络权重, 得到确定的网络模型, 即 $f(x)$ 。设计用于 QPE 的深度神经网络 (Quantitative Precipitation Estimation Network) QPENet 架构, 更准确的表达雷达观测与地面雨量的关系, 训练提出的网络模型并开展性能评估。

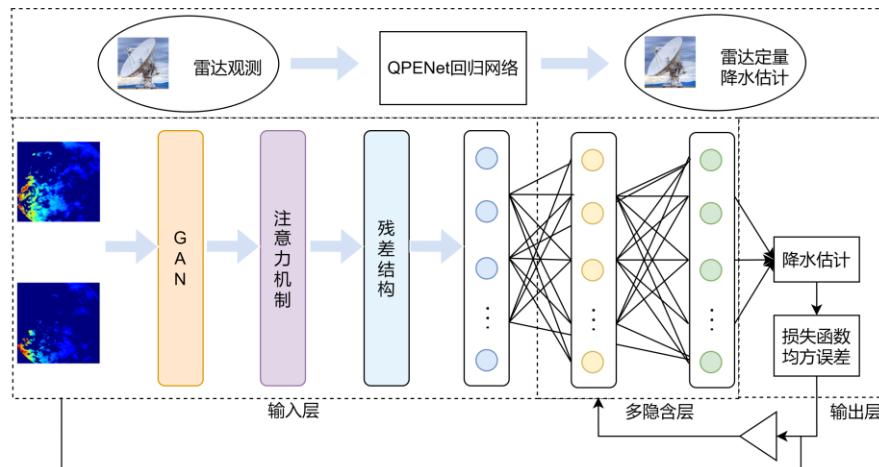


图 6-2 QPENet 模型架构、训练与估测示意图

本题在问题 1、问题 2 基础上提出降水估测模型, 本题中的模型选取问题 2 中的 U-Net 优化模型, 即 GAN-AR-U-Net 来开展降水估测研究。模型输入为 Z_H 、 Z_{DR} , 输出为降水量。大概描述 QPENet 的训练流程, 从左边开始, 经过数据质量控制的双线偏振雷达数据, 经与地面自动气象站对应后形成由 Z_H 、 Z_{DR} 两个偏振量构成的基数据矩阵输入网络, 通过由 GAN 数据增强、注意力机制、残差结构和 U-Net 等组成的多个隐含层后, 输出降水估测值, 计算与降水量观测值的误差, 采用 L2 损失函数、反向传播算法及优化算

法对各层的权重和偏置参数进行更新，直到网络估测的降水量与自动气象站观测的降水的误差不在减少或者小于某个设定的阈值时，停止训练网络。这时网络结构及其对应的所有参数就构成 QPENet 降水估测模型。

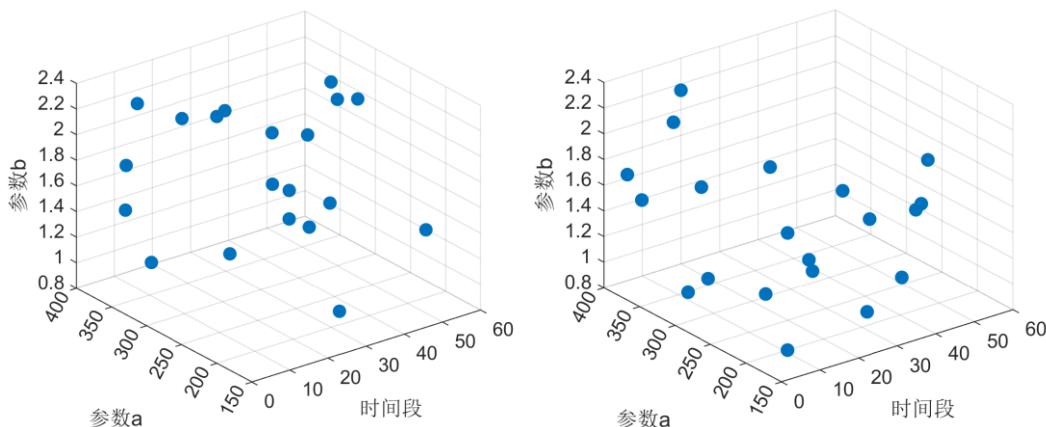
6.4.2 传统方法与深度学习法估测性能对比

使用 CC、RMSE、NE、NB 四个指标对 QPENet 模型的估测性能进行评估。三种模型评估指标对比表如下所示：

表 6-3 三种模型评估指标对比

模型	CC	RMSE	NE/%	NB/%
CFM	0.93	3.57	7.11	-10.92
U-Net	0.95	3.26	4.25	-6.14
GAN-AR-U-Net	0.96	2.14	3.81	2.55

多普勒天气雷达采用 Z-R 关系描述雷达反射率因子 (Z) 和降雨强度 (R) 的幂指数关系。中国的多普勒雷达普遍采用 $Z=aR^b$ ($a=300$, $b=1.4$) 进行降雨定量估计，但仅适用于平均情况。基于实测资料动态调整的 Z-R 关系，可以实现更加精确的降雨估计，动态 Z-R 关系的降雨定量估计精度最高，洪水模拟效果最好。动态 Z-R 关系建立在逐小时快速更新资料的基础上，通过动态调节参数 a 和 b ，使逐小时雷达估测降雨与对应的雨量站观测降雨的最优判别函数 δ 达到最小，从而确定适用于逐小时雷达定量降雨估计的多组 Z-R 关系参数。为保证参数 a 和 b 的取值合理，限定 a 和 b 数值调节范围为 [150.00,400.00]、[0.80,2.40]，调整间隔分别为 10 和 0.05。经过上述步骤最终确定出每场降雨过程的动态 Z-R 关系参数如图 6-3 所示。采用相关系数(Correlation coefficient, CC)、平均偏差 (Mean bias, BM)、平均绝对误差 (Mean absolute error, EMA) 进行降雨预报精度评价。



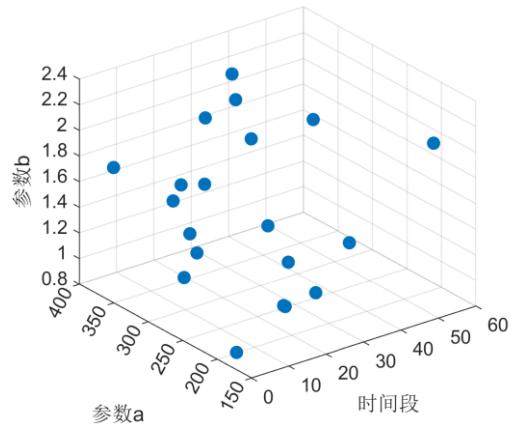


图 6-3 动态 Z—R 关系参数

在本题中，设计了一个基于深度学习的 QPE 深度卷积神经网络算法 QPENet。训练后的 QPENet 能够提高降水定量估测精度。通过评估，并与传统雨滴谱拟合方法 QPEDSD 对比，得到新算法 QPENet 具有更佳的性能并且估测更准。

七、问题 4 的模型建立与求解

7.1 问题分析

对问题四进行分析，可以将其分为两小问：

问题 4-1：设计数学模型来评估双偏振雷达数据在强对流降水临近预报中的贡献；

问题 4-2：优化数据融合策略，提高短临预测精度，以更好地应对突发性和局地性强的强对流天气。

问题 4 解题的技术路线如图所示：

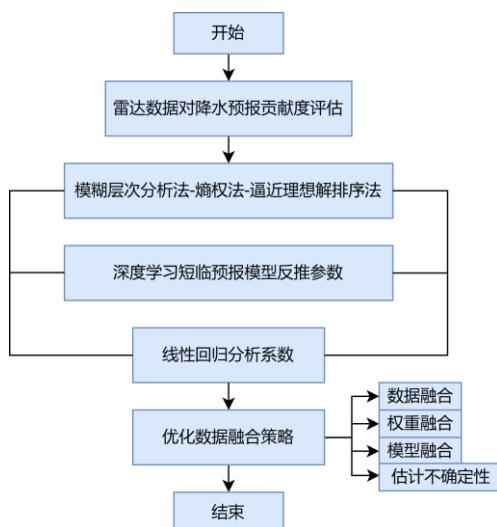


图 7-1 问题 4 技术路线图

7.2 基于模糊层次分析法-熵权法-逼近理想解排序法的双偏振雷达数据在强对流降水临近预报中的贡献度评估方法

为科学全面评估降水预报的贡献度，深度挖掘影响降水的因素和指标，首先，充分考虑双偏振雷达资料在降水量预报和降水微物理结构等方面的贡献，建立双偏振雷达资料“降水粒子半径-相态-含水量”的综合贡献度指标评估体系；其次，构建基于模糊层次分析法 - 熵权法 - 逼近理想解排序法的双偏振雷达资料贡献度评估方法，分析降水的微物理结构贡献度最优选择策略，并将方案进行灵敏度检验；最后，通过算例，分析双偏振雷达资料中的三个变量对降水微物理结构三个指标的综合贡献度，及其灵敏度，优化双偏振雷达变量数据融合策略，为降水微物理结构和预报提出参考性建议。

7.2.1 方法介绍

(1) 模糊层次分析法 (FAHP):

(a) 基本思想:

FAHP 是一种多准则决策分析方法，用于处理复杂的层次结构问题。其基本思想是将一个大的、复杂的决策问题分解成多个层次，从总体到细节逐级分析，然后通过模糊逻辑来处理不确定性和模糊性。

(b) 步骤:

构建层次结构：将问题划分成目标层、准则层和方案层。

制定判断矩阵：专家对准则的重要性进行两两比较，构建模糊判断矩阵。

计算权重：通过对模糊判断矩阵进行加权平均，计算出每个准则的权重。

一致性检验：检验判断矩阵的一致性，确保专家判断的一致性。

综合评估：将权重与方案的性能指标相结合，得出综合评价结果。

(c) 应用：

FAHP 广泛用于多准则决策问题，特别是需要处理模糊性和不确定性的情况。在上述问题中，FAHP 用于确定不同双偏振雷达参数的重要性权重。

(2) 熵权法 (Entropy Weight Method)：

(a) 基本思想：

熵权法是一种基于信息熵的权重确定方法。它通过计算每个指标的信息熵来衡量指标的随机性和不确定性，信息熵越大，权重越小。

(b) 步骤：

计算信息熵：对每个指标的数据进行归一化，计算信息熵。

计算权重：根据信息熵计算指标的权重，信息熵越大的指标权重越小。

标准化权重：将权重标准化，以确保它们之和等于 1。

(c) 应用：

熵权法适用于权重确定问题，特别是在没有专家知识的情况下，可以通过数据的统计性质来确定权重。在上述问题中，熵权法用于计算双偏振雷达参数的信息熵权重。

(3) 逼近理想解排序法 (TOPSIS)：

(a) 基本思想：

TOPSIS 是一种多属性决策方法，用于评估不同方案的相对优劣。它基于离理想解和接近反理想解的距离来排序方案，距离越小，方案越好。

(b) 步骤：

归一化决策矩阵：将决策矩阵的数据进行归一化，以消除不同指标之间的量纲差异。

确定理想解和反理想解：根据决策矩阵的性质，确定理想解和反理想解。

计算距离：计算每个方案到理想解和反理想解的距离。

综合评价：综合考虑到理想解和反理想解的距离，得出综合评价结果，按照距离的大小排序。

(c) 应用：

TOPSIS 用于多属性决策排序问题，可帮助确定哪个方案相对更优。在上述问题中，TOPSIS 用于评估双偏振雷达参数的贡献度，以确定其在临近预报中的重要性。

7.2.2 降水指标综合贡献度指标选取及计算方法

为了充分考虑双偏振雷达资料对降水量的影响，本文在降水指标维度选取降水粒子半径、相态、含水量 3 个指标，对双偏振雷达资料中三个指标 (Z_H 、 Z_{DR} 、 K_{DP}) 进行综合考虑。综合贡献度分为双偏振雷达一个一级指标，一级指标下又细分为 Z_H 、 Z_{DR} 、 K_{DP} ，3 个二级指标。具体指标如图 7-2 所示。

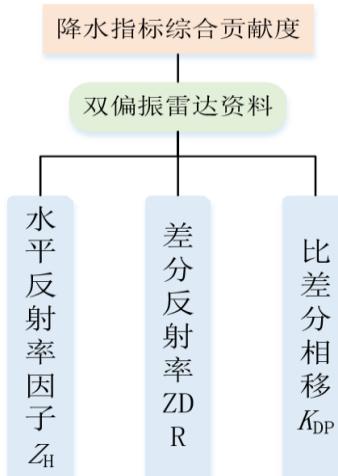


图 7-2 降水综合贡献度指标体系

本文在评估系统设置上综合运用主客观赋权法，采用模糊层级分析法(Fuzzy analytic hierarchy process, FAHP)和熵权法(Entropy weight method,EWM)组合的赋权方法进行评估，以便兼顾评估中的主观因素和客观因素。双偏振雷达变量对降水指标的综合贡献度主客观组合赋权模型如图 7-3 所示。

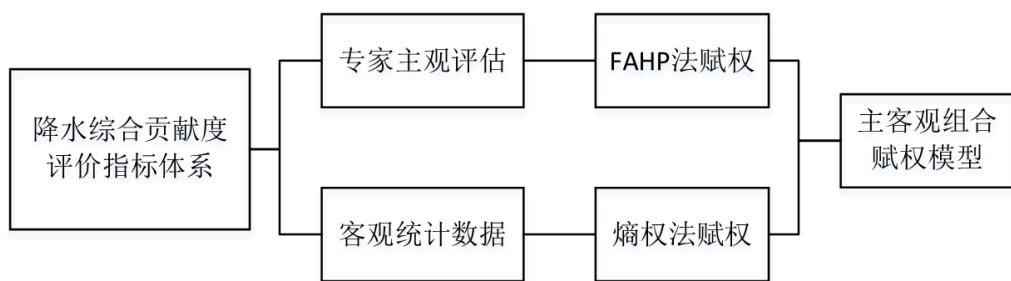


图 7-3 FAHP-EWM 组合主客观赋权模型

随后，运用主客观 FAHP-EWM 组合赋权模型确定指标权重，并用基于逼近理想解排序法判断最优选择策略，最后得到双偏振雷达变量对降水指标的综合贡献度评估模型结果，如图 7-4 所示。

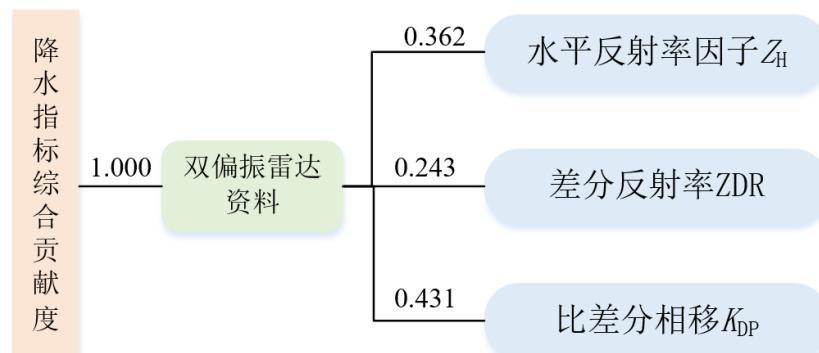


图 7-4 降水综合贡献度评估模型结果

根据 TOPSIS 原理，接近程度 C_i 的值越接近于 1，表明结果越接近最优值。结果显示，双偏振雷达变量对降水指标的综合贡献度排序为 $KDP > ZH > ZDR >$ 其他，排序结果如

下表 7-1 所示。

表 7-1 双偏振雷达变量最优策略排序结果

评价对象	最优向量 D_i^+	最差向量 D_i^-	接近程度 C_i	排序
水平反射率因子 Z_H	50.0055	5.4353	0.0980	4
差分反射率 Z_{DR}	33.3375	6.2555	0.1580	3
比差分相移 K_{DP}	20.1831	6.5772	0.2458	1
其他	22.0000	5.5168	0.2005	2

7.3 基于其他方法的贡献评估

分析模型的系数：如果你使用线性回归或类似方法，可以分析模型的系数来确定每个双偏振雷达特征对预报的贡献

比较不同模型：构建一个基准模型，不包括双偏振雷达数据，然后与包括双偏振雷达数据的模型进行比较，以评估其改进

不确定性估计：考虑估计双偏振雷达数据引入的不确定性，并确定其对预报的影响。这有助于了解在不同气象情境下模型的可靠性。

模型改进：如果发现双偏振雷达数据对预报有积极影响，可以进一步研究如何优化数据处理和模型参数，以提高预报的准确性。

7.4 数据融合策略优化研究

(1) 多源数据融合

在空间和时间上融合不同数据源的信息，以获取更全面的天气情报。这可以通过插值方法、空间统计方法等来实现。考虑气象过程的时空特性，以确定适当的时空融合策略实时监测和调整，建立一个实时监测系统，用于跟踪模型的性能和数据融合策略的表现根据实时观测数据和模型输出，及时调整权重和融合策略，以适应不同气象条件和突发事件。

(2) 权重融合

给传统雷达数据和双偏振雷达数据分配不同的权重，以反映它们在预报中的重要性。其中是一个权重系数，是传统雷达的预报结果，是双偏振雷达的预报结果。

$$R_{final} = \alpha \times R_{traditional} + (1 - \alpha) \times R_{dual-polarized} \quad (7.1)$$

通过数据分析和模型评估，确定不同数据源的权重。可以使用统计方法、优化算法或机器学习方法来自动调整权重。考虑制定动态权重策略，根据当前气象条件和预报性能来调整权重。例如，如果双偏振雷达在某种气象情境下表现更好，可以增加其权重。

(3) 模型融合

使用不同的预测模型，并结合它们的预测结果来提高预报的准确性。

(4) 估计数据的不确定性

估计每个数据源的不确定性，并将其纳入融合策略中。这可以通过统计方法或模型评估来实现。考虑使用卡尔曼滤波或蒙特卡洛方法等数据同化技术，以融合不确定性信息。

八、模型评价与推广

8.1 模型的优点

问题 1:

(1) U-Net 的编码器-解码器结构有助于保留图像的上下文信息。在强对流预报中，这有助于更好地理解天气系统的全局和局部结构。

(2) U-Net 使用跳跃连接（skip connections）将编码器和解码器层级之间的特征图相连接，从而促进了特征复用。这有助于提高预测的准确性。

问题 2:

(1) 采用生成对抗网络（GAN）用于数据增强，通过生成额外的训练数据，帮助提高深度学习模型的性能；

(2) 引入注意力机制和残差结构改进和优化 U-Net 模型，进一步提高了预测的准确率。

问题 3:

(1) 利用雨滴谱数据反推雷达观测数据。基于物理原理的方法。它依赖于雨滴谱、雷达波长、反射率之间的物理关系，因此提供了对降水过程的物理洞察；

(2) 利用 GAN-AR-U-Net 深度学习数据驱动模型，来学习 ZH 和 ZDR 之间的复杂非线性关系。可以从大量的 ZH 和 ZDR 观测数据中学习。这意味着模型可以不断优化和适应实际观测数据，提高了其泛化能力。

问题 4:

(1) 综合性评估：结合了模糊层次分析、熵权法和逼近理想解排序法，能够综合考虑多个评估因素，使得结果更加全面和准确。

(2) 适用性广泛：该方法适用于各种领域和问题，包括双偏振雷达资料的贡献度评估。因为它不仅仅考虑了数据本身的质量，还考虑了各种因素的重要性。

(3) 灵活性：这种方法可以根据具体问题和需求进行调整和定制，因此在不同情境下都可以得到有用的结果。

8.2 模型的缺点

(1) 尽管 GAN-AR-U-Net 具有很多优势，但也需要解决一些挑战，包括模型训练需要大量的标记数据、计算资源需求较高、模型解释性相对较低等问题；

(2) U-Net 需要克服标记数据和计算资源等方面的挑战，以实现最佳性能。

8.3 模型的改进与推广

(1) 本文所提模型适用于强对流降水临近预报问题；

(2) 模型不仅适用于降水的预报，还适用于雷雨、大风、冰雹等恶劣天气的预报；

(3) 本文模型是基于实际情况出发的，具有很强的现实意义。

参考文献

- [1] 国务院关于印发气象高质量发展纲要(2022—2035 年)的通知[J].中华人民共和国国务院公报,2022(16):11-16.
- [2] 苏爱芳,吕晓娜,崔丽曼等.郑州“7.20”极端暴雨天气的基本观测分析[J].暴雨灾害,2021,40(05):445-454.
- [3] Pan, X., Lu, Y., Zhao, K., Huang, H., Wang, M., & Chen, H. (2021). Improving Nowcasting of Convective Development by Incorporating Polarimetric Radar Variables Into a Deep - Learning Model. *Geophysical Research Letters*, 48(21), e2021GL095302.
- [4] Ravuri, S., Lenc, K., Willson, M., Kangin, D., Lam, R., Mirowski, P., ... & Mohamed, S. (2021). Skilful precipitation nowcasting using deep generative models of radar. *Nature*, 597, 672-677.
- [5] Zhang, Y., Long, M., Chen, K., Xing, L., Jin, R., Jordan, M. I., & Wang, J. (2023). Skilful nowcasting of extreme precipitation with NowcastNet. *Nature*, 619, 526 – 532.
- [6] Friedrich K, Higgins S, Masters F J, et al. Articulating and Stationary PARStVEL Disdrometer Measurements in Conditions with Strong Winds and Heavy Rainfall[J]. *Journal of Atmospheric and Oceanic Technology*, 2013, 30(9):2063 – 2080.
- [7] Yuter S E, Kingsmill D E, Nance L B, et al. Observations of Precipitation Size and Fall Speed Characteristics within Coexisting Rain and Wet Snow[J]. *Journal of Applied Meteorology and Climatology*, 2006, 45(10):1450 – 1464.
- [8] Tokay A, Bashor P G. An Experimental Study of Small-Scale Variability of Raindrop Size Distribution[J]. *Journal of Applied Meteorology and Climatology*, 2010, 49(11):2348 – 2365.
- [9] Zhao, K., Huang, H., Wang, M., Lee, W. C., Chen, G., Wen, L., ... & Chen, S. (2019). Recent progress in dual-polarization radar research and applications in China. *Advances in Atmospheric Sciences*, 36, 961-974.
- [10] Wen, J., Zhao, K., Huang, H., Zhou, B., Yang, Z., Chen, G., ... & Lee, W. C. (2017). Evolution of microphysical structure of a subtropical squall line observed by a polarimetric radar and a disdrometer during OPACC in Eastern China. *Journal of Geophysical Research: Atmospheres*, 122(15), 8033-8050.
- [11] Islam T, Rico-Ramirez M A, Thurai M, et al. 2012. Characteristics of raindrop spectra as normalized gamma distribution from a Joss-Waldvogel disdrometer. *Atmos res*, 108:57-73.
- [12] Park H S, Ryzhkov A V, Zrnic D S, et al. 2009. The hydrometeor classification algorithm for the polarimetric WSR-88D: Description and application to an MCS. *Wea Forecasting*, 24(3): 730-748.
- [13] 杨忠林,赵坤,徐坤等.江淮梅雨期极端对流微物理特征的双偏振雷达观测研究[J].气象学报,2019,77(01):58-72.
- [14] 李建柱,李磊菁,冯平等.基于深度学习的雷达降雨临近预报及洪水预报[J/OL].水科学进展:1-11.
- [15] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [16] Sutskever I , Vinyals O , Le Q V . Sequence to Sequence Learning with Neural Networks[J]. *Advances in neural information processing systems*, 2014, 27.

- [17] 刘黎平, 葛润生, 张沛源. 双线偏振多普勒天气雷达遥测降水强度和液态含水量的方法和精度研究[J]. 大气科学, 2002, 26(5):709-720.
- [18] Gorgucci E., Scarchilli G., Chandrasekar V. A robust estimator of rainfall rate using differential reflectivity[J]. J. Atmos. Oceanic Technol., 1994, 11(2):586-592.
- [19] Gorgucci E. and Scarchilli G. Intercomparison of multiparameter radar algorithms for estimating of rainfall rate[C]. In Preprints. 28th Conference on Radar Meteorology. Boston, MA, American Meteorological Society, 1997.
- [20] 曾晔, 加鹤萍, 杨菁等. 基于模糊层次分析法 - 熵权法 - 逼近理想解排序法的虚拟电厂综合贡献度评估方法[J/OL]. 现代电力:1-8[2023-09-26].

附录

程序 标号	1	程序说明	卡尔曼滤波代码	编程软件	Python
			<pre> pip install filterpy from filterpy.kalman import KalmanFilter import numpy as np import matplotlib.pyplot as plt # 生成带噪声的模拟测量数据 np.random.seed(0) true_values = np.linspace(0, 10, 100) measurements = true_values + np.random.normal(0, 1, size=100) # 创建卡尔曼滤波器 kf = KalmanFilter(dim_x=2, dim_z=1) # 定义状态转移矩阵 kf.F = np.array([[1, 1], [0, 1]]) # 定义测量矩阵 kf.H = np.array([[1, 0]]) # 定义状态协方差矩阵和测量噪声协方差矩阵 kf.P *= 1000 kf.R = 1 # 初始化状态向量和状态协方差矩阵 kf.x = np.array([0, 0]) kf.P = np.array([[1000, 0], [0, 1000]]) # 存储滤波后的估计值 filtered_state_means = [] # 逐帧处理测量数据 for measurement in measurements: # 预测步骤 kf.predict() # 更新步骤 kf.update(measurement) # 存储滤波后的状态估计值 filtered_state_means.append(kf.x[0]) # 绘制真实值、测量值和滤波后的估计值 plt.plot(true_values, label='True Values', linestyle='--', color='green') plt.plot(measurements, label='Measurements', marker='o', linestyle='-', color='blue') plt.plot(filtered_state_means, label='Filtered Estimate', color='red') plt.legend() plt.xlabel('Time Step') plt.ylabel('Value') plt.title('One-Dimensional Kalman Filter') plt.show() </pre>		
程序 标号	2	程序说明	U-net 基本模型代 码	编程软件	Python

```

import torch
import torch.nn as nn

# 定义U-Net模型
class UNet(nn.Module):
    def __init__(self, in_channels, out_channels):
        super(UNet, self).__init__()
        # 编码器（下采样）
        self.encoder = nn.Sequential(
            nn.Conv2d(in_channels, 64, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.Conv2d(64, 64, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=2, stride=2)
        )
        # 中间层
        self.middle = nn.Sequential(
            nn.Conv2d(64, 128, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.Conv2d(128, 128, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.MaxPool2d(kernel_size=2, stride=2)
        )
        # 解码器（上采样）
        self.decoder = nn.Sequential(
            nn.Conv2d(128, 64, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.Conv2d(64, 64, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.ConvTranspose2d(64, out_channels, kernel_size=2, stride=2)
        )
    def forward(self, x):
        # 编码器
        x1 = self.encoder(x)
        # 中间层
        x2 = self.middle(x1)
        # 解码器
        x3 = self.decoder(x2)

        return x3

# 创建U-Net模型实例
unet_model = UNet(in_channels=1, out_channels=1) # 输入和输出通道数可以根据任务进行调整

```

程序 标号	3	程序说明	ConvIstm 模型代码	编程软件	Python
			<pre> import torch import torch.nn as nn # 定义ConvLSTM单元 class ConvLSTMCell(nn.Module): def __init__(self, input_channels, hidden_channels, kernel_size): super(ConvLSTMCell, self).__init__() self.input_channels = input_channels self.hidden_channels = hidden_channels self.kernel_size = kernel_size padding = kernel_size // 2 # 输入门 self.Wxi = nn.Conv2d(self.input_channels, self.hidden_channels, self.kernel_size, padding=padding) self.Whi = nn.Conv2d(self.hidden_channels, self.hidden_channels, self.kernel_size, padding=padding) # 遗忘门 self.Wxf = nn.Conv2d(self.input_channels, self.hidden_channels, self.kernel_size, padding=padding) self.Whf = nn.Conv2d(self.hidden_channels, self.hidden_channels, self.kernel_size, padding=padding) # 候选状态 self.Wxc = nn.Conv2d(self.input_channels, self.hidden_channels, self.kernel_size, padding=padding) self.Whc = nn.Conv2d(self.hidden_channels, self.hidden_channels, self.kernel_size, padding=padding) # 输出门 self.Wxo = nn.Conv2d(self.input_channels, self.hidden_channels, self.kernel_size, padding=padding) self.Who = nn.Conv2d(self.hidden_channels, self.hidden_channels, self.kernel_size, padding=padding) def forward(self, x, h, c): # 输入门 i = torch.sigmoid(self.Wxi(x) + self.Whi(h)) # 遗忘门 f = torch.sigmoid(self.Wxf(x) + self.Whf(h)) # 候选状态 c_tilde = torch.tanh(self.Wxc(x) + self.Whc(h)) # 更新细胞状态 c = f * c + i * c_tilde # 输出门 o = torch.sigmoid(self.Wxo(x) + self.Who(h)) # 更新隐藏状态 h = o * torch.tanh(c) return h, c </pre>		

```

# 定义ConvLSTM模型
class ConvLSTM(nn.Module):
    def __init__(self, input_channels, hidden_channels, kernel_size, num_layers):
        super(ConvLSTM, self).__init__()
        self.input_channels = input_channels
        self.hidden_channels = hidden_channels
        self.kernel_size = kernel_size
        self.num_layers = num_layers
        cell_list = []
        for i in range(self.num_layers):
            cur_input_channels = self.input_channels if i == 0 else self.hidden_channels
            cell_list.append(ConvLSTMCell(cur_input_channels, self.hidden_channels, self.kernel_size))
        self.cell_list = nn.ModuleList(cell_list)

    def forward(self, input):
        h, c = [None] * self.num_layers, [None] * self.num_layers
        for i in range(self.num_layers):
            h[i], c[i] = self.cell_list[i](input, h[i - 1], c[i - 1]) if i > 0 else self.cell_list[i](input, h[i], c[i])
        return h[-1]

# 创建ConvLSTM模型实例
input_channels = 3
hidden_channels = 64
kernel_size = 3
num_layers = 2
convlstm_model = ConvLSTM(input_channels, hidden_channels, kernel_size, num_layers)

```

程序 标号	4	程序说明	GAN 模型代码	编程软件	Python
----------	---	------	----------	------	--------

```

import torch
import torch.nn as nn

# 定义生成器网络
class Generator(nn.Module):
    def __init__(self, input_dim, output_dim):
        super(Generator, self).__init__()
        self.fc = nn.Sequential(
            nn.Linear(input_dim, 128),
            nn.ReLU(),
            nn.Linear(128, output_dim),
            nn.Tanh()
        )

    def forward(self, x):
        return self.fc(x)

# 定义判别器网络
class Discriminator(nn.Module):
    def __init__(self, input_dim):
        super(Discriminator, self).__init__()
        self.fc = nn.Sequential(
            nn.Linear(input_dim, 128),
            nn.ReLU(),
            nn.Linear(128, 1),
            nn.Sigmoid()
        )

    def forward(self, x):
        return self.fc(x)

# 定义生成器和判别器的输入维度和模型实例
input_dim = 100 # 生成器的输入维度
output_dim = 784 # 生成器的输出维度 (MNIST图像大小)
discriminator_input_dim = 784 # 判别器的输入维度 (MNIST图像大小)

generator = Generator(input_dim, output_dim)
discriminator = Discriminator(discriminator_input_dim)

# 定义损失函数和优化器
criterion = nn.BCELoss() # 二元交叉熵损失
optimizer_G = torch.optim.Adam(generator.parameters(), lr=0.0002)
optimizer_D = torch.optim.Adam(discriminator.parameters(), lr=0.0002)

```

```

# 训练GAN
num_epochs = 100
batch_size = 64

for epoch in range(num_epochs):
    for batch in data_loader: # 这里需要提供数据加载器
        # 训练判别器
        optimizer_D.zero_grad()
        real_data = batch.view(batch_size, -1)
        real_labels = torch.ones(batch_size, 1)
        fake_data = generator(torch.randn(batch_size, input_dim))
        fake_labels = torch.zeros(batch_size, 1)

        outputs_real = discriminator(real_data)
        outputs_fake = discriminator(fake_data)

        loss_real = criterion(outputs_real, real_labels)
        loss_fake = criterion(outputs_fake, fake_labels)
        loss_D = loss_real + loss_fake
        loss_D.backward()
        optimizer_D.step()

        # 训练生成器
        optimizer_G.zero_grad()
        fake_data = generator(torch.randn(batch_size, input_dim))
        outputs_fake = discriminator(fake_data)
        loss_G = criterion(outputs_fake, real_labels)
        loss_G.backward()
        optimizer_G.step()

    print(f"Epoch [{epoch + 1} / {num_epochs}] Loss D: {loss_D.item()}, Loss G: {loss_G.item()}")

# 最后，生成器可以用来生成图像
with torch.no_grad():
    random_input = torch.randn(1, input_dim)
    generated_image = generator(random_input)

```

程序标号	5	程序说明	对获得的数据结果利用 matlab 进行绘图	编程软件	Matlab
			<pre> %% 柱形图 % 生成数据 %1KM data = [0.71 0.72; 0.68 0.7; 0.65 0.63 ; 0.6 0.53;0.58 0.56; 0.55 0.52; 0.57 0.51; 0.47 0.46; 0.43 0.41; 0.39 0.38]; bar(data) xlabel('X轴') ylabel('Y轴') legend('U-Net','ConvLSTM') % set(gca,'XTick',[6:6:60]); xlabel('Forecast Minutes(*6)','FontSize',11) ylabel('CSI','FontSize',11); %3KM data = [0.71 0.70; 0.68 0.67; 0.65 0.61 ; 0.6 0.55;0.58 0.56; 0.55 0.51; 0.57 0.55; 0.47 0.46; 0.43 0.40; 0.39 0.35]; bar(data) xlabel('X轴') ylabel('Y轴') legend('U-Net','ConvLSTM') % set(gca,'XTick',[6:6:60]); xlabel('Forecast Minutes(*6)','FontSize',11) ylabel('CSI','FontSize',11); %7KM data = [0.71 0.68; 0.68 0.65; 0.65 0.57 ; 0.6 0.53;0.58 0.51; 0.55 0.52; 0.57 0.47; 0.46 0.45; 0.43 0.41; 0.35 0.33]; bar(data) xlabel('X轴') ylabel('Y轴') legend('U-Net','ConvLSTM') % set(gca,'XTick',[6:6:60]); xlabel('Forecast Minutes(*6)','FontSize',11) ylabel('CSI','FontSize',11); %% CSI x = [0, 6, 12, 18, 24, 36, 42, 48, 54, 60]; d1 = [0.71, 0.68, 0.65, 0.6, 0.58, 0.55, 0.57, 0.5, 0.47, 0.44]; d2 = [0.72, 0.7, 0.63, 0.57, 0.56, 0.52, 0.51, 0.48, 0.46, 0.37]; d3 = [0.70, 0.68, 0.61, 0.54, 0.50, 0.46, 0.43, 0.41, 0.38, 0.36]; % 自定义颜色 c1 = [193, 219, 18] / 255; c2 = [255, 163, 137] / 255; c3 = [255, 169, 188] / 255; % 绘制折线图并应用自定义颜色 plot(x, d1,'LineWidth', 1.2, 'Color', c1,'Marker', 'o'); set(gca,'XTick',[6:6:60]); hold on plot(x, d2,'LineWidth', 1.2, 'Color', c2,'Marker', '+'); plot(x, d3,'LineWidth', 1.2, 'Color', c3,'Marker', '*'); legend('U-Net','GAN-U-Net','GAN-AR-U-Net') xlabel('Forecast Minutes','FontSize', 11) ylabel('CSI','FontSize', 11); set(gca,'FontSize',11); % 设置坐标轴字体大小 </pre>		

```

%% POD
x = [0, 6, 12, 18, 24, 36, 42, 48, 54, 60];
d1=[0.71,0.68,0.65,0.6,0.58,0.55,0.57,0.5,0.47,0.44];%最优
d3=[0.70,0.68,0.61,0.54,0.50,0.46,0.43,0.41,0.38,0.36];
d4=[0.64,0.6,0.58,0.55,0.51,0.50,0.47,0.37,0.35,0.32];

% 自定义颜色
c1 = [193, 219, 18] / 255;
c2 = [255, 163, 137] / 255;
c3 = [255, 169, 188] / 255;

% 绘制折线图并应用自定义颜色
plot(x, d1, 'LineWidth', 1.2, 'Color', c1,'Marker', 'o');
set(gca, 'XTick', [6:6:60]);
hold on
plot(x, d3, 'LineWidth', 1.2, 'Color', c2,'Marker', '+');
plot(x, d4, 'LineWidth', 1.2, 'Color', c3,'Marker', '');
legend('U-Net','GAN-U-Net','GAN-AR-U-Net');
xlabel('Forecast Minutes','FontSize', 11);
ylabel('POD','FontSize', 11);
set(gca,'Fontsize',11); % 设置坐标区字体大小

%% FAR
x = [0, 6, 12, 18, 24, 36, 42, 48, 54, 60];
d1=[0.64,0.6,0.58,0.55,0.51,0.50,0.47,0.37,0.35,0.32];
d4=[0.73,0.72,0.64,0.59,0.56,0.53,0.50,0.46,0.42,0.34];
d5=[0.71,0.68,0.65,0.6,0.58,0.55,0.57,0.5,0.47,0.44];%最优

% 自定义颜色
c1 = [193, 219, 18] / 255;
c2 = [255, 163, 137] / 255;
c3 = [255, 169, 188] / 255;

% 绘制折线图并应用自定义颜色
plot(x, flip(d1), 'LineWidth', 1.2, 'Color', c1,'Marker', 'o');
set(gca, 'XTick', [6:6:60]);
hold on
plot(x, flip(d4), 'LineWidth', 1.2, 'Color', c2,'Marker', '+');
plot(x, flip(d5), 'LineWidth', 1.2, 'Color', c3,'Marker', '');
legend('U-Net','GAN-U-Net','GAN-AR-U-Net');
xlabel('Forecast Minutes','FontSize', 11);
ylabel('FAR','FontSize', 11);
set(gca,'Fontsize',11); % 设置坐标区字体大小

x=[0, 6, 12, 18, 24, 36, 42, 48, 54, 60];
d1=[0.71,0.68,0.65,0.6,0.58,0.55,0.57,0.5,0.47,0.44];%最优
d2=[0.72,0.7,0.63,0.57,0.56,0.52,0.51,0.48,0.46,0.37];
d3=[0.70,0.68,0.61,0.54,0.50,0.46,0.43,0.41,0.38,0.36];
plot(x,d1,'k-o','Linewidth',1.2)
set(gca, 'XTick', [6:6:60]);
hold on
plot(x,d2,'k-+','Linewidth',1.2);
plot(x,d3,'k-*','Linewidth',1.2);
legend('U-Net','GAN-U-Net','GAN-AR-U-Net')
xlabel('Forecast Minutes','FontSize',11);
ylabel('CSI','FontSize',11);
grid on

```

程序标号	6	程序说明	原始数据批量处理以及可视化	编程软件	Matlab
			<pre> %% 降雨可视化 for k=1:257 figure('Position',[400,2,103,4,842,4,664]),tiledlayout(4,4) for i=1:4 for j=1:4 index=(i-1)*4+j; path=[\NJU_CPOL_kdpRain\NJU_CPOL_kdpRain\data_dir_sprintf('%03d',k)\frame_\sprintf('%03d',index).mat']; data=load(path); nexttile.imagesc(data.data); axis equal; xlim([0,256]); set(gca, 'XTick', []); set(gca, 'YTick', []); title(['frame_',sprintf('%03d',index)]); end end img_path=[\NJU_CPOL_kdpRain\NJU_CPOL_kdpRain\data_dir_sprintf('%03d',k).png]; exportgraphics(gcf,img_path,'Resolution',300) end </pre>		
			<pre> figure('Position',[400,2,103,4,842,4,664]),tiledlayout(4,4) for i=1:4 for j=1:4 index=(i-1)*4+j; path=[\NJU_CPOL_kdpRain\NJU_CPOL_kdpRain\data_dir_000\frame_\sprintf('%03d',index).mat']; data=load(path); nexttile.imagesc(data.data); axis equal; xlim([0,256]); set(gca, 'XTick', []); set(gca, 'YTick', []); title(['frame_',sprintf('%03d',index)]); end end </pre>		

```

%% dBZ可视化
for k=1:257
    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\1.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\1.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\3.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\3.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\7.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\dBZ\7.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

end

%% KDP可视化
for k=1:257
    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\1.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\1.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\3.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\3.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

    figure('Position',[400,2,103.4,842.4,664]),tiledlayout(4,4)
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\7.0km\data_dir_,sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\KDP\7.0km\data_dir_,sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path,'Resolution',300)

end

```

```

%% ZDR可视化
for k=1:257
    figure('Position',[400,2,103,4,842,4,664]),tiledlayout(4,4),
    for i=1:4
        for j=1:4
            index=(i-1)*4+j;
            path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\ZDR\1.0km\data_dir_];sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
            data=load(path);
            nexttile,imagesc(data.data);
            axis equal
            xlim([0,256])
            set(gca, 'XTick', []);
            set(gca, 'YTick', []);
            title(['frame\_',sprintf('%03d',index)])
        end
    end
    img_path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\ZDR\1.0km\data_dir_];sprintf('%03d',k),'.png']
    exportgraphics(gcf,img_path, 'Resolution',300)

figure('Position',[400,2,103,4,842,4,664]),tiledlayout(4,4)
for i=1:4
    for j=1:4
        index=(i-1)*4+j;
        path=[\NJU_CPOL_update2308\NJU_CPOL_update2308\ZDR\3.0km\data_dir_];sprintf('%03d',k),\frame_,sprintf('%03d',index),'.mat']
        data=load(path);
        nexttile,imagesc(data.data);
        axis equal
        xlim([0,256])
        set(gca, 'XTick', []);
        set(gca, 'YTick', []);
        title(['frame\_',sprintf('%03d',index)])
    end
end

```